Univerzitet u Sarajevu
Elektrotehnički fakultet
Odsjek za računarstvo i informatiku

Projekat na temu

Detekcija anomalija na medicinskim slikama

- Prepoznavanje oblika i obrada slike -

Studenti:

Ali Ljaljak (2340/19371)
Daris Mujkić (19413/2432)
Amina Kazazović (19364/2413)
Benjamin Hadžihasanović (2427/19319)
Elma Tirak (2336/19282)

Sarajevo, 2025.

1. Definicija, ciljevi i plan izrade projektnog zadatka **3**
1.1 Definicija **3**
1.2 Ciljevi 3
1.3 Plan izrade 3
1.4 Moguća ograničenja 5
2. Analiza naučnih radova **6**
2.1 Naučni rad 1 6
Classification of brain tumor types through MRIs using parallel CNNs and firefly optimization 6
2.2 Naučni rad 2 9
Advanced Brain Tumor Classification in MR Images Using Transfer Learning and Pre-Trained Deep CNN Models 9
2.3 Naučni rad 3 13
Brain Tumor Classification from MRI Using Image Enhancement and Convolutional Neural Network Techniques” 13
2.4 Naučni rad 4 18
An Attentive Multi-Modal CNN for Brain Tumor Radiogenomic Classification 18
2.5 Naučni rad 5 22
Brain Tumor Characterization Using Radiogenomics in Artificial Intelligence Framework 22
3. Analiza odabranog dataseta **28**
Uvod 28
3.1 Naziv skupa podataka i izvor 28
3.2 Opis i svrha 28
3.3 Struktura skupa podataka 28
3.4 Veličina skupa podataka 29
3.5 Tipovi podataka 30
3.6 Raspodjela podataka 31
3.7 Kvalitet i varijabilnost slika 32
3.8 Informacije o kontekstu 34
3.9 Razlog za izbor skupa podataka 35
3.10 Najbitnije informacije iz skupa podataka 36
4. Opis modela i metodologija implementacije **37**
4.1 Specifičnosti modela 37
4.2 Arhitektura neuronske mreže (Slojevi i dimenzije) 38
4.3 Parametri treniranja i optimizacija 40
4.4 Podjela skupa podataka 41
4.5 Evaluacijske metrike 41

5. Rezultati i evaluacija modela **42**
5.1 Proces treniranja i pretraga hiperparametara 42
5.1.1 Modifikacija arhitekture 42
5.1.2 Eksperimenti sa hiperparametrima 43
5.2 Performanse konačnog modela 43
5.2.1 Ukupna tačnost i gubitak 43
5.2.2 Analiza po klasama 44
5.2.3 Matrica konfuzije i analiza grešaka 45
5.3 Diskusija i interpretacija rezultata 47
5.3.1 Uspješnost modela 47
5.3.2 Vizuelna analiza tipičnih slučajeva grešaka 48
6. Grafički korisnički interfejs (GUI) **50**
6.1 Uvod 50
6.2 Implementirane verzije interfejsa 50
6.2.1 Desktop verzija (Tkinter) 50
6.2.2 Web verzija (Gradio) 50
6.3 Instalacija i pokretanje 51
6.3.1 Desktop verzija - Lokalno pokretanje 51
6.3.2 Web verzija - Google Colab 53
6.4 Tok rada u aplikaciji 53
6.5 Budući razvoj GUI-a 54
6.6 Zaključak o GUI implementaciji 54
7. Zaključak **55**
8. Literatura **56**

1. Definicija, ciljevi i plan izrade projektnog zadatka

1.1 Definicija

Tema projektnog zadatka se odnosi na automatsku klasifikaciju MRI snimaka mozga pomoću tehnika digitalne obrade slike i metoda dubokog učenja. Konkretan zadatak je prepoznavanje vizuelnih obrazaca na MRI slikama i njihovo svrstavanje u četiri kategorije: glioma, meningioma, pituitary tumor i slike bez tumora.

MRI slike predstavljaju složene strukture sa neujednačenim osvjetljenjem, kontrastom i šumom, što otežava, ručno prepoznavanje obrazaca i granica tumora [1], [3]. Stoga, cilj ovog projekta je primijeniti principe obrade slike (normalizacija, filtriranje, poboljšanje kontrasta, izdvajanje bitnih regiona) i metode konvolucijskih neuronskih mreža kako bi se detektovali karakteristični oblici i teksture koje razlikuju slike sa i bez tumora [2], [3].

Rješenje ovog problema ima praktičan značaj jer demonstrira kako se znanje iz obrade slike i prepoznavanja oblika može primijeniti na realan medicinski dataset [5].

1.2 Ciljevi

- Primijeniti metode digitalne obrade slike na MRI snimke radi poboljšanja kvaliteta i ekstrakcije važnih karakteristika [3]
- Analizirati vizuelne osobine MRI slika (tekstura, granice, oblici, kontrast, osvjetljenje)
- Razviti plan buduće implementacije modela koji može da klasifikuje MRI slike u 4 kategorije
- Izdvojiti relevantno područje slike (mozak) iz pozadinskih margina [3]
- Testirati kako kvalitet slike utiče na performanse modela
- Osigurati balansirano treniranje uprkos nejednakoj zastupljenosti klasa

1.3 Plan izrade

1. korak: Istraživanje teme i skupa podataka
Istraživanje teme klasifikacije tumora mozga koristeći metode obrade slike. Analiziraju se osnovni pojmovi MRI snimanja, različite vrste tumora i specifične karakteristike medicinskih slika. Vrši se pregled dostupnih datasetova, nakon čega se bira najpogodniji za projekat.

2. korak: Analiza naučnoistraživačkih radova
Pregled relevantne literature iz oblasti obrade slike, prepoznavanja oblika i primjene dubokog učenja na medicinske slike. Proučavaju se postojeće arhitekture CNN modela [2], metode preprocesiranja [3], tehnike poboljšanja slike [3], kao i različiti pristupi klasifikaciji tumora mozga. Cilj je identifikovati najbolje prakse, mogućnosti poboljšanja i prepoznati koje metode mogu biti primjenjene u okviru ovog projekta.

3. korak: Analiza skupa podataka
Detaljna analiza odabranog dataset-a: raspodjela slika po klasama, dimenzije, osvjetljenje, kontrast, tipovi slika, varijabilnost slika i prisustvo šuma. Uočavaju se razlike između klasa, učestalost pojedinih kategorija, vizuelne karakteristike tumora i na taj način se donose zaključci koje se tehnike za preprocesiranje mogu iskoristiti.

4. korak: Definiranje problema i ciljeva projekta
Definiše se problem koji podrazumijeva klasifikaciju MRI slika u 4 klase pomoću tehnika obrade slike i CNN-a. Ciljevi su: standardizacija slika, kreiranje CNN modela i evaluacija njegovih performansi na odabranom datasetu.

5. korak: Početak implementacije
Učitavanje slike iz trening i testnog skupa podataka, a zatim se primjenjuju metode preprocesiranja kao što su: uklanjanje margina, normalizacija piksela, veličina slike, poboljšavanje kontrasta, augmentacija (rotacija, zoom, flipping) [1], [3].

6. korak: Opis izabranog modela/tehnike/metode
Odabir jedne CNN arhitekture, opis kako izgleda arhitektura, koje slojeve ćemo koristiti i kako će taj model obrađivati slike.

7. korak: Implementacija izabranog modela/tehnike/metode i treniranje
Implementacija modela i treniranje kroz epohe na unaprijed pripremljenim podacima. Posmatra se *accuracy* i *loss* tokom treninga. Prati se overfitting.
8. korak: Evaluacija modela i fine-tuning parametara

Testiranje modela na testnom skupu iz dataseta i izračunavanje *accuracy*, *precision*, *recall*. Ukoliko rezultati nisu zadovoljavajući mijenja se *learning rate*, *broj epoha*, dodavanje *dropout-a*, mijenanje arhitekture. Cilj je dobiti stabilniji i precizniji model uz minimalan overfitting.

9. korak: Kreiranje korisničkog interfejsa i pisanje zaključka
Pravi se jednostavan GUI gdje korisnik učita sliku i dobije predikciju klase. Analiziraju se postignuti rezultati i piše se konačni zaključak.

1.4 Moguća ograničenja

- Različite dimenzije slika u dataset-u - otežava standardizaciju
- Pogrešan cropping može ukloniti važne dijelove mozga ili ostaviti suvišne elemente koji zbunjuju model
- Varijabilnost u osvjetljenju i kontrastu između klasa- otežava učenje modela [3]
- Disbalans klasa može uticati na preciznost
- Prisustvo šuma i neujednačenog intenziteta signala što može otežati ekstrakciju karakteristika i zahtijeva filtriranje ili normalizaciju [1], [3].
- Moguć overfitting zbog razlika u kvalitetu slika

2. Analiza naučnih radova

2.1 Naučni rad 1

Classification of brain tumor types through MRIs using parallel CNNs and firefly optimization

Publikacija: Li, C., Zhang, F., Du, Y. & Li, H. (2024). *Classification of brain tumor types through MRIs using parallel CNNs and firefly optimization*. Scientific Reports, 14, 15057. https://www.nature.com/articles/s41598-024-65714-w

1. Sažetak publikacije

Ovaj rad predstavlja hibridni model za automatsku klasifikaciju tumora mozga sa MRI snimaka, konkretno fokusirajući se na razlikovanje između tumora visokog stepena (HGG) i niskog stepena (LGG). Problem koji se rješava je izazov precizne i efikasne segmentacije i klasifikacije tumora, što je ključno za dijagnostiku i planiranje liječenja [1].

Autori predlažu **dvije ključne inovacije**:

1. **Nova tehnika segmentacije** koja koristi optimizacijski algoritam **Firefly Optimization (FFO)**. Umjesto tradicionalnih metoda, FFO se koristi za pronalaženje optimalnih pragova intenziteta piksela kako bi se što preciznije izdvojio region tumora (ROI) od zdravog tkiva [1].
2. **Paralelna Konvolutivna Neuronska Mreža (PCNN)** za klasifikaciju. Ovaj model se sastoji od dvije odvojene CNN grane koje istovremeno obrađuju različite vrste karakteristika iz segmentiranog tumora, nakon čega se njihovi rezultati spajaju za konačnu odluku [1].

Koristeći **BRATS2018** skup podataka, predloženi model je postigao visoku prosječnu **tačnost od 98.6%**, nadmašujući nekoliko drugih postojećih metoda [1].

2. Korištene metode

Metodologija rada je podijeljena u tri glavne faze:

Predprocesiranje (Preprocessing)

1. **Skup podataka:** Korišteni su podaci iz **BRATS2018** baze, specifično HGG i LGG klase. Iz 3D MRI snimaka ekstrahovano je **500 2D isječaka (slices)** (255 HGG, 245 LGG). 2. **Normalizacija:** Slike su normalizovane (min-max skaliranje) i primijenjena je ekvilizacija histograma za poboljšanje kontrasta.
3. **Uklanjanje pozadine:** Korišten je jednostavan prag (threshold) i morfološke operacije (erozija) da se ukloni lobanja i pozadina, ostavljajući samo moždano tkivo.
4. **Promjena veličine:** Slike su smanjene na **200x200** piksela.

Segmentacija i identifikacija ROI (Region of Interest)

Ovo je prva ključna inovacija rada. Cilj je bio precizno izdvojiti samo područje tumora.

1. **Hibridni K-Means i FFO:** Proces segmentacije modeliran je kao optimizacijski problem.
    - **K-Means** algoritam se prvo koristi da grubo procijeni centre klastera (regija) na slici. Ovi centri služe kao **početna populacija** za FFO algoritam, što ubrzava konvergenciju [1].
    - **Firefly Optimization (FFO):** Ovaj algoritam zatim iterativno podešava pragove intenziteta piksela (svjetline) kako bi pronašao optimalnu podjelu slike na K regiona [1].
2. **Fitness funkcija:** Da bi FFO znao šta je "dobra" segmentacija, koristi se funkcija cilja (fitness) koja pokušava:
    - **Minimizirati** udaljenost unutar klastera (pikseli unutar jedne regije trebaju biti što sličniji).
    - **Maksimizirati** udaljenost između klastera (različite regije trebaju biti što različitije).
    - **Minimizirati** entropiju (svaka regija treba biti što uniformnija).
3. **Ekstrakcija ROI:** Nakon što FFO segmentira sliku, regija koja odgovara tumoru (obično ona s najvećim intenzitetom) se identifikuje kao Region od Interesa (ROI) [1].

Klasifikacija (Paralelna CNN)

Ovo je druga ključna inovacija. Umjesto jednog CNN-a, koriste se dva koja rade paralelno.

1. **Grana 1: 1D CNN + LBP (Lokalni Binarni Obrasci)**
    - Prvo se iz ROI slike ekstrahuju **LBP karakteristike**. LBP je moćan deskriptor **teksture** slike.
    - Ove teksturalne karakteristike (koje su u formi 1D vektora) se zatim šalju u relativno jednostavnu **1D Konvolutivnu Mrežu**. Ova grana uči da prepoznaje obrasce u *teksturi* tumora.
2. **Grana 2: 2D CNN**

○ Sama **2D slika (matrica piksela)** segmentiranog ROI-a se šalje u standardnu **2D Konvolutivnu Mrežu**. Ova grana uči prostorne i morfološke karakteristike tumora (oblik, ivice, itd.).

3. **Fuzija karakteristika:**
   ○ Nakon što obje grane obrade svoje ulaze, vektori karakteristika (feature vectors) iz posljednjih slojeva obje mreže se **spajaju (konkateniraju)** u jedan dugi vektor. ○ Ovaj kombinovani vektor, koji sadrži i informacije o teksturi (iz 1D) i o obliku (iz 2D), prosljeđuje se u **SoftMax** klasifikator za konačnu odluku: HGG ili LGG [1].

3. Ostvareni rezultati

Model je evaluiran koristeći 10-struku unakrsnu validaciju (10-fold cross-validation) na 500 slika.

● **Glavni rezultat:** Postignuta je prosječna **tačnost (Accuracy) od 98.6%** [1].

● **Ostali pokazatelji:** Model je također postigao odlične rezultate na drugim metrikama:
○ **Preciznost (Precision):** 0.9844
○ **Odziv (Recall):** 0.9882
○ **F-mjera (F-Measure):** 0.9863
○ **AUC (Area Under ROC Curve):** 0.9882

Poređenje (Ablation Study): Najvažniji dio rezultata je poređenje s varijantama sopstvenog modela:

1. **Predloženi model (FFO + PCNN): 98.6%**
2. **Model bez FFO segmentacije:** Tačnost je bila **5% niža**. Ovo dokazuje da je inovativni FFO korak segmentacije bio **izuzetno važan** za visoke performanse.
3. **Model sa samo 2D CNN (Prop. 2DCNN): 94.6%**. Ovo pokazuje da je dodavanje paralelne 1D grane za LBP teksture značajno poboljšalo klasifikaciju.
4. **Poređenje sa drugim radovima:** Model je nadmašio i druge metode testirane na sličnim podacima, kao što je DACBT[21] (97.6%) [1].

4. Prednosti i nedostaci

Prednosti (Advantages)

● **Visoka tačnost:** Rezultat od 98.6% je izuzetno visok i konkurentan u ovoj oblasti. ● **Inovativna segmentacija:** Upotreba FFO (Firefly Optimization) kao optimizacijske tehnike za segmentaciju je netipična i pokazala se veoma efikasnom (donijela je 5% poboljšanja). Ovo je snažna strana modela [1].

- **Hibridni model karakteristika (PCNN):** Kombinovanje 1D teksturalnih (LBP) i 2D prostornih (raw pixels) karakteristika putem paralelne CNN arhitekture omogućava modelu da "vidi" problem iz dva različita ugla, što je očigledno poboljšalo rezultate u odnosu na korištenje samo 2D CNN-a [1].
- **Računarska efikasnost:** Autori tvrde da model ima relativno mali broj parametara (~8.4 miliona) i nisku memorijsku zahtjevnost (oko 33.5 MB), što ga čini efikasnim i primjenjivim na različitim sistemima [1].

Nedostaci i ograničenja (Disadvantages and Limitations)

- **Veličina skupa podataka:** Model je treniran i testiran na samo **500 2D isječaka**. Iako je BRATS2018 standard, ovo je relativno mali skup podataka. Nije jasno da li bi se performanse održale na mnogo većem i raznovrsnijem skupu (npr. desetine hiljada slika iz različitih bolnica) [1].
- **Složenost implementacije:** Model nije "end-to-end". Zahtijeva složen cjevovod (pipeline) od više koraka: predprocesiranje, pa FFO optimizacija za segmentaciju, pa LBP ekstrakcija, pa paralelni CNN. Ovo je znatno kompleksnije za implementaciju i održavanje nego korištenje jedne, standardne CNN arhitekture (poput U-Net ili ResNet) [1].
- **Binarna klasifikacija:** Rad se bavi samo binarnom klasifikacijom (HGG vs. LGG). Mnogi stvarni problemi zahtijevaju višeklasnu klasifikaciju (npr. Glioma, Meningioma, Pituitary tumor). Model nije testiran u tom scenariju [1].
- **FFO parametri:** Performanse FFO algoritma mogu zavisiti od njegovih hiperparametara (npr. veličina populacije, broj iteracija). Iako je inicijalizacija K-Meansom pametan potez, algoritam i dalje može biti osjetljiv na podešavanja [1].

2.2 Naučni rad 2

Advanced Brain Tumor Classification in MR Images Using Transfer Learning and Pre-Trained Deep CNN Models

Autori: Rukiye Disci, Fatih Gurcan, Ahmet Soylu

Publikacija: *Cancers*, 2025, 17, 121 https://www.mdpi.com/2072-6694/17/1/121

1. Sažetak publikacije

Ovaj naučni rad istražuje primjenu unaprijed treniranih modela dubokog učenja (Deep Learning) za automatsku klasifikaciju tumora na mozgu korištenjem snimaka magnetne rezonance (MR). Cilj studije je bio procijeniti efikasnost šest poznatih arhitektura konvolucijskih neuronskih mreža (CNN) u razlikovanju četiri kategorije: **Glioma**, **Meningioma**, **Pituitarni tumor** i **snimci bez tumora (No Tumor)**. Koristeći javno dostupan skup podataka, autori su primijenili tehniku transfernog učenja (Transfer Learning) kako bi prilagodili postojeće modele specifičnom zadatku klasifikacije tumora [2].

Model nazvan **Xception** pokazao se kao najuspješniji, postižući ponderisanu tačnost od 98.73%. Studija naglašava da, iako su modeli pokazali odlične ukupne performanse, i dalje postoje izazovi u preciznom prepoznavanju određenih tipova tumora. Zaključak je da duboko učenje ima ogroman potencijal da transformiše medicinsku dijagnostiku, čineći je bržom, pouzdanijom i efikasnijom [2].

2. Korištene metode

Autori su primijenili sistematski pristup koji se sastojao od nekoliko ključnih koraka:

- **Skup podataka (Dataset):** Korišten je javno dostupan "Brain Tumor MRI Dataset" sa platforme Kaggle, koji sadrži ukupno 7023 MR snimka. Skup je podijeljen na 5712 snimaka za trening i 1311 za testiranje, ravnomjerno raspoređenih u četiri navedene klase.
- **Predobrada podataka (Data Preprocessing):** Kako bi se poboljšao kvalitet podataka i smanjila računarska zahtjevnost, provedeni su sljedeći koraci:
    - **Konverzija u sive tonove (Grayscale):** Slike u boji su pretvorene u crno-bijele jer boja ne nosi relevantne informacije za ovaj tip klasifikacije.
    - **Zamagljivanje (Blurring):** Primijenjen je Gaussov filter za smanjenje šuma na slikama.
    - **Segmentacija i izdvajanje regije od interesa (ROI):** Pomoću binarne thresholding tehnike i detekcije kontura, automatski je identifikovano i izrezano područje na kojem se nalazi tumor (ili mozak, u slučaju snimaka bez tumora). Time se model fokusira samo na relevantne dijelove slike [2].
    - **Promjena veličine (Resizing):** Sve slike su standardizovane na dimenziju 128x128 piksela.
- **Augmentacija podataka (Data Augmentation):** Kako bi se povećala raznolikost trening skupa i spriječilo prekomjerno prilagođavanje (overfitting), primijenjene su nasumične

transformacije na slikama, poput promjene svjetline i kontrasta. Nakon toga, vrijednosti piksela su normalizovane na raspon od 0 do 1.

- **Modeli i transferno učenje:** Studija je implementirala i uporedila šest poznatih unaprijed treniranih CNN modela:
    - **Xception**
    - **MobileNetV2**
    - **InceptionV3**
    - **ResNet50**
    - **VGG16**
    - **DenseNet121**
- Ovi modeli su originalno trenirani na ogromnom ImageNet skupu podataka. Korištenjem transfernog učenja, njihovo naučeno znanje o prepoznavanju opštih karakteristika na slikama preneseno je i fino podešeno (fine-tuning) za specifičan zadatak klasifikacije tumora mozga. Na osnovni model dodana je prilagođena klasifikacijska glava koja se sastoji od Flatten sloja, dva Dropout sloja za regularizaciju i dva Dense (potpuno povezana) sloja [2].
- **Proces treniranja:** Modeli su trenirani korištenjem **Adam optimizatora** sa niskom stopom učenja (0.0001), funkcijom gubitka sparse_categorical_crossentropy i praćenjem metrike tačnosti. Trening je trajao 5 epoha sa veličinom batch-a od 20 slika [2].

3. Ostvareni rezultati

Performanse modela su evaluirane korištenjem standardnih metrika: tačnost (accuracy), preciznost (precision), odziv (recall) i F1-score.

- **Najbolji model: Xception** je ostvario najbolje rezultate sa ponderisanom tačnošću (Weighted Accuracy Avg) od **98.73%** i testnom tačnošću od 95.27%. Također je imao i najbolji ponderisani F1-score od 95.29%, što ukazuje na dobar balans između preciznosti i odziva [2].
- **Poređenje modela:**
    1. **Xception (98.73%)**
    2. **MobileNetV2 (98.15%)**
    3. **InceptionV3 (97.43%)**
    4. **ResNet50 (97.41%)**
    5. **VGG16 (96.80%)**

6. **DenseNet121 (95.83%)**

- **Analiza po klasama:** Većina modela je postigla skoro savršene rezultate u identifikaciji klase "No Tumor". Međutim, pokazali su nešto slabije performanse (konkretno, niži odziv) za klase **Glioma** i **Meningioma**, što znači da su povremeno propuštali da identifikuju postojeći tumor [2].
- **Generalizacija:** Model Xception je pokazao jaku sposobnost generalizacije, s malom razlikom između performansi na trening i test skupu, što ukazuje na minimalan overfitting. S druge strane, modeli poput ResNet50 pokazali su veći jaz, što sugeriše sklonost ka prekomjernom prilagođavanju [2].

4. Prednosti i nedostaci

Prednosti:

- **Sistematičan pristup:** Rad detaljno poredi šest modernih i široko prihvaćenih arhitektura na istom skupu podataka, pružajući jasan uvid u njihove relativne performanse. ● **Reproducibilnost:** Korištenje javno dostupnog skupa podataka omogućava drugim istraživačima da ponove i provjere rezultate [2].
- **Efikasnost transfernog učenja:** Studija potvrđuje da transferno učenje značajno smanjuje potrebno vrijeme za treniranje i računarske resurse, a istovremeno omogućava postizanje visoke tačnosti [2].
- **Napredna predobrada:** Koraci poput automatskog izdvajanja regije od interesa (ROI) pomažu modelu da se fokusira na bitne karakteristike, što doprinosi boljim performansama [2].
- **Visoka tačnost:** Ostvarena tačnost od 98.73% pokazuje da su ovakvi sistemi izuzetno obećavajući za kliničku primjenu kao pomoćno sredstvo radiolozima [2].

Nedostaci (ograničenja):

- **Ograničena raznolikost podataka:** Skup podataka, iako balansiran, potiče iz jednog izvora. Nedostaju mu varijacije u tipovima MR uređaja, protokolima snimanja i demografskim podacima pacijenata, što može ograničiti primjenjivost modela u različitim kliničkim okruženjima [2].
- **Nedostatak eksterne validacije:** Model nije testiran na potpuno nezavisnom skupu podataka iz druge institucije, što je ključan korak za potvrdu njegove robusnosti. ● **Problem "crne kutije" (Black Box):** Kao i većina modela dubokog učenja, i ovi modeli ne daju jasno objašnjenje zašto su donijeli određenu odluku. To predstavlja prepreku za njihovo puno

prihvatanje u medicinskoj praksi gdje je transparentnost ključna. ● **Slabije performanse za određene klase:** Niži odziv za Glioma i Meningioma ukazuje na to da model može propustiti dijagnozu, što je u medicini kritičan problem [2].

2.3 Naučni rad 3

Brain Tumor Classification from MRI Using Image Enhancement and Convolutional Neural Network Techniques”

Naziv rada: Brain Tumor Classification from MRI Using Image Enhancement and Convolutional Neural Network Techniques

Autori: Zahid Rasheed, Yong-Kui Ma, Inam Ullah, et al.

Publikacija: Brain Sciences, 2023, 13(9), 1320, https://www.mdpi.com/2076-3425/13/9/1320

1. Sažetak publikacije

Ovaj naučni rad se bavi problemom klasifikacije tumora na mozgu pomoću snimaka magnetne rezonance (MRI). Zbog složenosti i dugotrajnosti procesa, ručna detekcija i klasifikacija tumora sklona je greškama. U radu se predlaže nova metodologija koja integriše tehnike za poboljšanje slike sa konvolucionom neuronskom mrežom (CNN) kako bi se efikasno klasifikovale različite vrste tumora na mozgu: gliom, meningiom i tumor hipofize, kao i slučajevi bez tumora. Autori su za poboljšanje kvaliteta slike koristili oštrenje zasnovano na Gausovom zamućenju i adaptivnu ekvalizaciju histograma sa ograničenim kontrastom (CLAHE). Predloženi model je testiran na javno dostupnom skupu podataka i upoređen sa postojećim pre-treniranim modelima kao što su VGG16, ResNet50, VGG19, InceptionV3 i MobileNetV2. Rezultati su pokazali izuzetnu tačnost predloženog modela u klasifikaciji najčešćih tipova tumora na mozgu [3].

2. Korištene metode

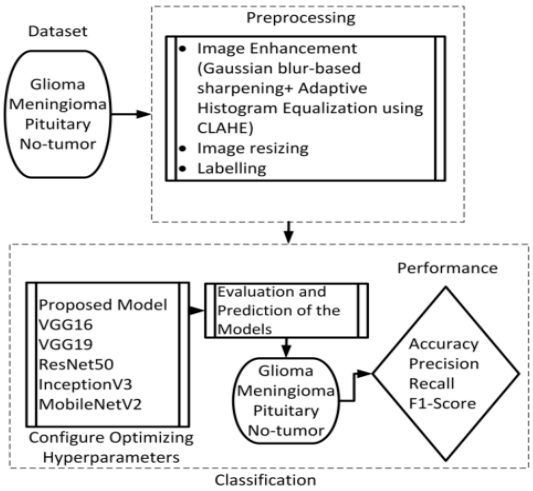

Slika 1: Dijagram toka sistema korištenog za klasifikaciju (preuzeto iz [3])

Metodologija predstavljena u ovom radu sastoji se od dvije ključne faze:

- **Predobrada slike:** U cilju poboljšanja kvaliteta ulaznih MRI snimaka, primijenjene su dvije tehnike:
  - **Oštrenje zasnovano na Gausovom zamućenju (Gaussian-blur-based sharpening):** Ova tehnika naglašava ivice i detalje na slici.
  - **Adaptivna ekvalizacija histograma sa ograničenim kontrastom (CLAHE):** Ova metoda poboljšava lokalni kontrast slike, čineći tumore vidljivijim.
- **Klasifikacija pomoću konvolucione neuronske mreže (CNN):**
  - **Arhitektura modela:** Autori su dizajnirali specifičnu CNN arhitekturu prilagođenu za klasifikaciju tumora na mozgu.
  - **Skup podataka:** Korišten je javno dostupan skup podataka koji je kombinacija tri druga skupa: Figshare, SARTAJ i BR35H. Ukupan skup podataka sadrži 7023 MRI snimka. Ovaj skup podataka je dostupan na linku:

https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset

  - **Trening i evaluacija:** Model je treniran tokom 30 epoha sa veličinom batch-a (batch size) od 8. Za evaluaciju performansi i robusnosti predloženog modela, autori su primijenili tehniku 5-struke unakrsne validacije (5-fold cross-validation). Ovaj postupak podrazumijeva nasumičnu podjelu skupa podataka na pet jednakih dijelova ili "nabora" (folds). Model se zatim iterativno trenira pet puta, pri čemu se u svakoj iteraciji kompletan trening od 30 epoha izvršava na četiri nabora, dok

se peti koristi za validaciju. Konačne metrike performansi, poput tačnosti i F1-skora, izračunate su kao prosjek rezultata dobijenih iz svih pet ciklusa. Ovakav pristup osigurava da je svaki dio podataka iskorišten i za treniranje i za validaciju, čime se dobija pouzdanija i stabilnija procjena sposobnosti modela da generalizuje na novim, neviđenim podacima [3].

Analiza strukture korištene neuronske mreže

Autori su razvili prilagođenu arhitekturu konvolucione neuronske mreže (CNN) umjesto da se oslanjaju isključivo na pre-trenirane modele. Struktura je dizajnirana da efikasno uči karakteristike relevantne za tumore mozga iz MRI snimaka dimenzija 224x224 piksela [3].

Ključni elementi arhitekture su:

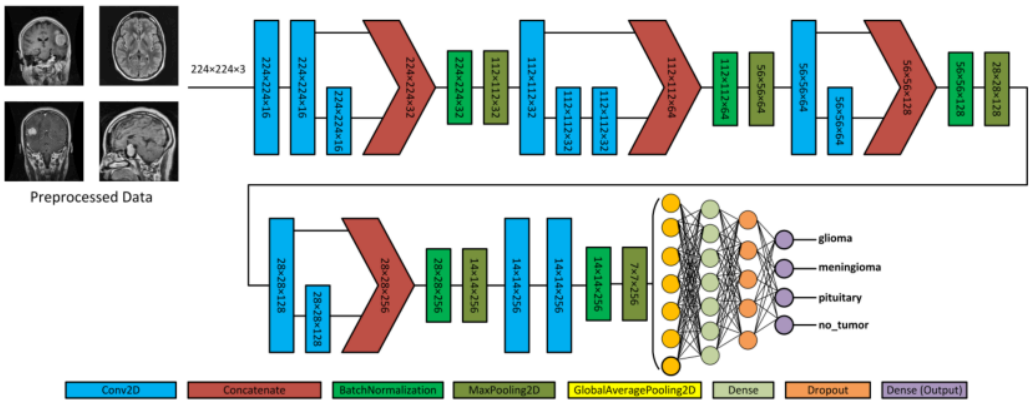

Slika 2: Ilustracija predložene arhitekture duboke neuronske mreže (preuzeto iz [3])

- **Konvolucioni blokovi:** Mreža se sastoji od niza konvolucionih blokova. Svaki blok je dizajniran da uči sve složenije karakteristike slike. Broj filtera se postepeno povećava kroz mrežu (16, 32, 64, 128, 256), što omogućava modelu da u početnim slojevima detektuje jednostavne oblike (ivice, teksture), a u dubljim slojevima kompleksnije strukture specifične za tumore [3].
- **Skip Connections (Veze preskakanja):** Unutar svakog bloka koriste se "skip connections" koje spajaju izlaze iz različitih konvolucionih slojeva. Ova tehnika, popularizovana u mrežama poput ResNet-a, pomaže u ublažavanju problema nestajućeg gradijenta i omogućava bolji protok informacija kroz duboke mreže. To osigurava da se važne informacije iz ranijih slojeva ne izgube [3].
- **Batch Normalization:** Nakon svakog konvolucionog sloja primjenjuje se normalizacija serije (batch normalization). Ona stabilizuje i ubrzava proces treniranja normalizacijom ulaza u svaki sloj [3].
- **Max Pooling:** Koristi se za smanjenje dimenzionalnosti (downsampling) mapa karakteristika, čime se smanjuje broj parametara i računarska složenost, a zadržavaju najvažnije informacije [3].

- **Klasifikacijski dio:** Nakon konvolucionih blokova, mreža ima:
    - **Global Average Pooling (GAP):** Ovaj sloj drastično smanjuje broj parametara prije potpuno povezanih slojeva, što pomaže u smanjenju preprilagođavanja (overfitting).
    - **Gusti sloj (Dense Layer):** Sastoji se od 512 neurona sa ReLU aktivacionom funkcijom, koji uče kombinacije karakteristika iz prethodnih slojeva [3].
    - **Regularizacija:** Na gusti sloj se primjenjuju L1 i L2 regularizacija, kao i **Dropout** sa stopom od 50%. Dropout nasumično "isključuje" neurone tokom treninga, što tjera mrežu da uči robusnije karakteristike i poboljšava njenu sposobnost generalizacije.
    - **Izlazni sloj:** Završni sloj koristi **Softmax** aktivacionu funkciju koja daje vjerovatnoću za svaku od četiri klase (gliom, meningiom, tumor hipofize, bez tumora).

Za treniranje ove arhitekture korišten je Adam optimizator, koji efikasno prilagođava težine mreže kako bi se minimizirala funkcija gubitka. Pored toga, implementiran je i ReduceLROnPlateau callback. Ova tehnika dinamički smanjuje stopu učenja (learning rate) tokom treninga ukoliko se primijeti da performanse modela na validacijskom skupu stagniraju, što omogućava finije podešavanje modela i pomaže u postizanju boljeg konačnog rezultata [3].

3. Ostvareni rezultati

Predložena metodologija je postigla izvanredne rezultate u klasifikaciji tumora na mozgu:

- **Tačnost (Accuracy):** 97.84%
- **Preciznost (Precision):** 97.85%
- **Odziv (Recall):** 97.85%
- **F1-skor:** 97.90%

Usporedba sa pretreniranim modelima:

Analiza tabele jasno pokazuje superiornost predloženog modela u svim ključnim aspektima. Ne samo da ostvaruje najvišu tačnost od 97.84%, nadmašujući sve pre-trenirane arhitekture, već to postiže uz izuzetnu efikasnost. Sa samo ~1.7 miliona parametara i najbržim vremenom testiranja od 0.83 sekunde, model je znatno lakši i brži od konkurencije. Međutim, ključni kompromis leži u njegovoj specijalizaciji; za razliku od pre-treniranih modela koji posjeduju opšte znanje sa velikih skupova podataka, predloženi model je treniran "od nule" isključivo za ovaj zadatak. To ga čini visoko optimizovanim za klasifikaciju tumora na mozgu, ali potencijalno manje prilagodljivim za druge probleme u poređenju sa fleksibilnijim, pre-treniranim arhitekturama [3].

4. Prednosti i nedostaci

Prednosti:

- **Visoka tačnost:** Predloženi model postiže izuzetno visoku tačnost u klasifikaciji [3].

- **Inovativna predobrada:** Integracija specifičnih tehnika za poboljšanje slike značajno doprinosi boljim performansama [3].
- **Prilagođena arhitektura:** Dizajnirana CNN arhitektura je efikasnija za ovaj specifičan problem u poređenju sa nekim generičkim pre-treniranim modelima, a istovremeno ima manji broj parametara [3].
- **Robusna evaluacija:** Korištenje 5-struke unakrsne validacije osigurava pouzdanost prikazanih rezultata.

Nedostaci:

- **Ovisnost o skupu podataka:** Performanse na potpuno novim, neviđenim podacima iz drugih izvora tek treba da budu potvrđene [3].
- **Fokus na 2D slikama:** Rad se bavi 2D MRI snimcima. Analiza 3D snimaka mogla bi pružiti potpuniju sliku.
- **Ograničena interpretabilnost:** Kao i kod većine modela dubokog učenja, može biti teško u potpunosti razumjeti zašto je model donio određenu odluku.

2.4 Naučni rad 4

An Attentive Multi-Modal CNN for Brain Tumor Radiogenomic Classification

Autori: Ruyi Qu, Zhifeng Xiao

Publikacija: Department of Mathematics, University of Toronto, Toronto, ON M5S 2E4, Canada School of Engineering, Penn State Erie, The Behrend College, Erie, PA 16563, USA
Information **2022**, *13*(3), 124; **https://doi.org/10.3390/info13030124**

Sažetak publikacije

U ovom radu autori se bave dijagnostikovanjem tumora mozga pomoću MRI slika. Spajanjem jedinstvenih osobina svakog modaliteta MRI snimka može se tačno odrediti priroda tumora. Trenutno se status tumora obično utvrđuje genetičkom analizom, ali je ona spora i zahtjeva operativno uzimanje uzorka tkiva, stoga autori predlažu duboki neuronski model koji može da predvidi prirodu tumora. Njihov model je tesitran na RSNA-MICCAI skupu podataka i nadmašio je najjače postojeće modele za oko 3% [4].

Uvod

U uvodu rada objašnjava se ozbiljnost tumora mozga, posebno glioblastoma (GBM) koji spada u jedan od najagresivnijih i najsmrtonosnijih tumora. Prema određenim globalnim statistikama svake godine se pojavi preko 300 000 novih slučajeva, a navode i da GBM ima ekstremno nisku stopu preživljavanja i ograničene mogućnosti liječenja. Ovdje autori naglašavaju da je potrebna neinvazivna metoda i stavljaju u fokus MRI snimke i tehnike dubokog učenja. Kako MRI snimci imaju više modaliteta, svaki modalitet otkriva različite karakteristike tkiva, pa je cilj ovog rada da poboljša performanse modela zahvaljujući pametnijoj upotrebi svih modaliteta snimaka [4]. Predložena je nova DNN arhitektura sa **tri ključne inovacije**:

1) Lite attention - lagani mehanizam pažnje koji određuje težinu svakog modaliteta uz manju složenost.
2) Separable embedding- dodatni modul koji poboljšava reprezentaciju podataka prije klasifikacije.
3) Modal-wise shortcuts- prečice koje pomažu da se zadrže originalne informacije iz svakog

modaliteta.

Navedene tehnike su kombinovane sa multimodalnim pristupom i na taj način su poboljšali tačnost klasifikacije MGMT metilacije za oko 3% u odnosu na dosadašnja najbolja rješenja [4].

Magnetna rezonanca (MRI) predstavlja ključni izvor informacija u dijagnostici tumora mozga, a uz to nudi različite modalitete snimanja - FLAIR, T1, T1Gd i T2 pri čemu svaki modalitet otkriva specifične anatomske i biohemijske karakteristike tkiva. Također, u brojnim radovima koristio se samo jedan modalitet ili vrlo jednostavna fuzija podataka, dok su napredne tehnike multimodalnog učenja bile rijetko primjenjene. Većina ranijih istraživanja koristila je manje datasetove podataka, što je značajno uticalo na kvalitet i generalizaciju modela. Kako bi se popunili ovakvi nedostaci autori ovog rada predlažu da se uvede model koji kombinuje četiri ključna elementa: multimodalnu ekstrakciju karakteristika, lite attention mehanizam, separabilni embedding modul i modal-wise shortcut strategiju. Svaki od ovih elemenata ima specifičnu ulogu u poboljšanju obrade podataka i performansi modela. Multimodalna ekstrakcija karakteristika omogućava da se svaki MRI modalitet obradi zasebno, čuvajući specifičnosti koje nosi. Lite attention mehanizam služi za određivanje relativne važnosti svakog modaliteta uz znatno smanjenu kompleksnost u poređenju s klasičnim attention tehnikama. Model-wise shortcut omogućava direktno propuštanje originalnih informacija prije spajanja modaliteta, čime se sprječava gubitak važnih detalja tokom obrade. Separabilni embedding modul koristi dodatni CNN i omogućava dublju transformaciju podataka prije sekvencijalnog učenja putem LSTM-a [4].

Korištene metode

Autori su u ovom radu predložili arhitekturu duboke neuronske mreže (DNN): 1. **Agregacija multi-modalnih karakteristika:** Radi se ekstrakcija karakteristika iz svake od četiri modalnosti MRI skenova (FLAIR, T1w, T1Gd, i T2) zasebno, zbog značajnih razlika u principima snimanja. Koristi se jednostavna jednoslojna konvolucija kao ekstraktor karakteristika kako bi se očuvale originalne informacije

2. **Lite mehanizam pažnje (Lite Attention Mechanism):** Umjesto sekvencijalnih RNN modela, koristi se mehanizam pažnje za spajanje karakteristika iz različitih modalnosti. Predloženi "lite" mehanizam pažnje direktno modeluje težine različitih modalnosti, smanjujući broj parametara za obuku i poboljšavajući brzinu obuke i performanse generalizacije.
3. **Modalno-specifični prečica (Modal-Wise Shortcut):** Da bi se spriječio gubitak detaljnih informacija tokom procesa fuzije, dodaje se rezidualna veza između originalnog ulaza i izlaza modula pažnje za svaku modalnost. Ovo omogućava da se originalne detaljne karakteristike zadrže u mreži.

4. **Separabilno ugrađivanje (Separable Embedding):** Karakteristike se mapiraju u novi separabilni prostor pomoću zasebne CNN (CNNSE), prije nego što se proslijede detekcionom sloju.
5. **LSTM i detekcioni sloj:** Niz tensorskih podataka, poredan po vremenskom koraku MRI skenova, unosi se u Long Short-Term Memory (LSTM) mrežu, praćenu potpuno povezanim slojem i sigmoidnom funkcijom za dobijanje verovatnoće MGMT promotorske metilacije [4].

Dataset

Dataset koji je korišten u radu je **RSNA-MICCAI 2021** koj isadrži MRI snimke **585 pacijenata** i predstavlja jedan od najvećih i najraznovrsnijih trenutno dostupnih skupova podataka u ovoj oblasti. Svaki pacijent ima četiri modaliteta MRI snimka i veliki broj slika po modalitetu, što dataset čini pogodnim za multimodalni pristup. Autori su selektovali najinformativnije slike na osnovu intenziteta signala i kreirali prošireni dataset tako što su iz svakog pacijenta izdvojili deset reprezentativnih setova snimaka. Trening je izveden korištenjem Adam optimizatora, augmentacije podataka i pažljivo podešenih hiperparametara [4].

Ostvareni rezultati

Model postiže tačnost od **63.71%** na validacionom skupu, što predstavlja **poboljšanje od 3% u odnosu na tadašnje metode** i pokazuju da ovakav pristup ima ključnu ulogu u ostvarivanju boljih rezultata. Ipak, primjetno je da postoji izražen problem overfittinga što se pripisuje varijabilnosti MRI snimaka, neujednačenom kvalitetu podataka i činjenici da veliki broj slika prikazuje samo djelimične segmente mozga [4].

Prednosti i nedostaci

Prednosti

- **Poboljšana tačnost:** Model postiže bolju tačnost klasifikacije (63.71%) u poređenju sa SOTA modelima (60.74%).
- **Neinvazivna metoda:** Predložena metoda nudi neinvazivnu i efikasnu alternativu za određivanje statusa MGMT metilacije, za razliku od genetske analize koja zahtjeva hirurško vađenje uzoraka moždanog tkiva.
- **Efikasna obrada multi-modalnih podataka:** Integracija multi-modalnih MRI skenova

omogućava iskorištavanje bogatih informacija iz različitih modalnosti, što dovodi do boljih karakteristika i obrazaca za učenje.

- **Lagana arhitektura:** Uvođenje "lite" mehanizma pažnje smanjuje broj parametara i poboljšava brzinu obuke i generalizaciju modela.
- **Očuvanje detalja:** Modalno-specifični prečica pomaže u očuvanju originalnih detaljnih karakteristika, sprečavajući degradaciju performansi.
- **Dobra generalizacija:** Korištenje RSNA-MICCAI skupa podataka sa većim brojem pacijenata i MRI skenova doprinosi boljoj generalizaciji modela.
- **Otvoreni kod:** Dostupnost izvornog koda projekta kao otvorenog referencu za buduća istraživanja [4].

Nedostaci i budući rad

- **Pretjerano prilagođavanje (Overfitting):** Uočeno je pretjerano prilagođavanje kod svih evaluiranih modela, gde su rezultati obuke bili znatno bolji od rezultata validacije. To ukazuje da modeli nisu naučili dovoljno dobro generalizovati na neviđene podatke.
- **Fokus na temporalnu povezanost:** Metoda razmatra samo temporalnu povezanost između podataka iste modalnosti, ali ne ispituje odnos između različitih modalnosti. - **Nedostatak pažnje na pojedinačne slike:** Rad se ne bavi pažnjom na nivou pojedinačnih slika unutar modalnosti, što bi moglo da otkrije kritične oblasti MRI skenova sa informativnim obrascima.
- **Nema integrisane segmentacije tumora:** Predlaže se da budući rad uključi zajednički model koji obrađuje i segmentaciju tumora i MGMT detekciju.
- **Potreba za više podataka:** Iako je skup podataka veći od prethodnih, mnogi skenovi pokrivaju samo delimične oblasti mozga, što ograničava broj ekspresivnih obrazaca za učenje.
- **Ograničena objašnjivost:** Iako mehanizmi pažnje pomažu u razumijevanju koje karakteristike su važne, model i dalje može biti "crna kutija" u smislu potpunog objašnjenja *zašto* donosi određene odluke [4].

Zaključak

Na samom kraju ovog naučnog rada autori naglašavaju da rezultati još nisu na nivou kliničke primjene, ali da model predstavlja značajan korak naprijed ka pouzdanim, neinvazivnim metodama za predikciju MGMT metilacije. Iako rad pruža dobar uvid u jasne prednosti u tačnosti i efikasnosti, kroz njega se prepoznaje potreba za daljim istraživanjem inter-modalnih odnosa i pažnje na nivou slike [4].

2.5 Naučni rad 5

Brain Tumor Characterization Using Radiogenomics in Artificial Intelligence Framework

Referenca: Jena, B.; Saxena, S.; Nayak, G.K.; et al. Brain Tumor Characterization Using Radiogenomics in Artificial Intelligence Framework. *Cancers* 2022, *14*, 4052.

1. Sažetak publikacije

Ovaj naučni rad predstavlja sistematski pregled, čiji je cilj da pruži dubinsku analizu i sumira trenutno stanje u inovativnom polju radiogenomike, sa fokusom na njegovu primjenu u karakterizaciji tumora mozga pomoću vještačke inteligencije [5].

Radiogenomika je polje koje nastoji uspostaviti vezu između radiomike i genomike. Radiomika je kvantitativna analiza medicinskih snimaka koja izdvaja brojne karakteristike koje opisuju fenotip tumora (oblik, teksturu, veličinu..). Ovo je napredna ekstrakcija karakteristika iz slikovnih podataka. Genomika analizira molekularni i genetski sastav tumora. Ovo se posmatra kao analiza "izvornog koda" bolesti [5].

Glavni cilj radiogenomike je razvoj AI modela koji mogu, isključivo na osnovu radioloških snimaka predvidjeti ključne genetske karakteristike tumora. Time se otvara mogućnost izbjegavanja rizičnih hirurških biopsija, što predstavlja revolucionaran pomak u dijagnostici. Autori su, koristeći strogu PRISMA metodologiju, analizirali 165 relevantnih studija kako bi identifikovali dominantne tehnologije, metodološke pristupe, ostvarene rezultate i ključne izazove koji stoje pred ovim poljem [5].

2. Korištene metode

Kao sistematski pregled, rad ne razvija novi algoritam, već primjenjuje metodologiju za prikupljanje, selekciju i sintezu postojećih metoda.

2.1. PRISMA Model i Strategija Pretrage

Osnova metodologije je PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses) protokol, koji garantuje transparentnost i ponovljivost procesa. Proces je uključivao:

1. **Identifikaciju**: Pretraga šest prominentnih naučnih baza (PubMed, IEEE Xplore, Google Scholar, itd.) koristeći precizno definisane ključne riječi.
2. **Selekciju (Screening):** Uklanjanje duplikata i radova koji ne odgovaraju temi na osnovu naslova i sažetka.
3. **Procjenu prihvatljivosti (Eligibility):** Detaljna analiza punih tekstova radova kako bi se osiguralo da ispunjavaju sve unaprijed definisane kriterijume (npr. da koriste AI, da se bave radiogenomikom tumora mozga).
4. **Uključivanje:** Finalni odabir od 165 publikacija za kvalitativnu sintezu [5].

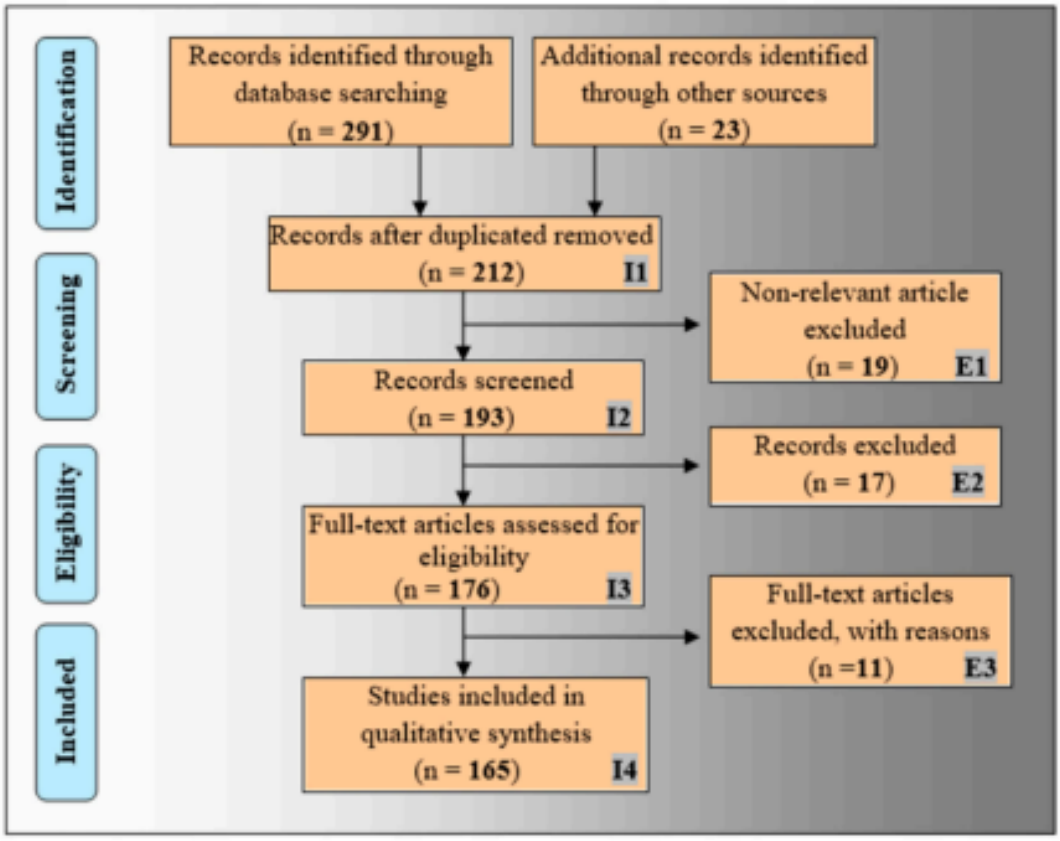

Slika 3: PRISMA flowchart - sistematski proces selekcije relevantnih naučnih radova (preuzeto iz [5])

2.2. Statistička analiza i mapiranje polja

Autori su proveli statističku analizu odabranih studija po nekoliko ključnih dimenzija:

● **Geografska distribucija:** Analiza porijekla istraživanja po državama. ● **AI tehnologije:** Distribucija studija koje koriste klasično mašinsko učenje (ML), duboko učenje (DL) i transferno učenje (TL).

● **Korišteni AI modeli i klasifikatori:** Identifikacija najpopularnijih arhitektura (npr. CNN, ResNet, VGG) i algoritama za klasifikaciju (npr. Softmax, Random Forest, SVM). ● **Modaliteti snimanja:** Zastupljenost različitih tehnika snimanja (MRI, CT, PET) [5].

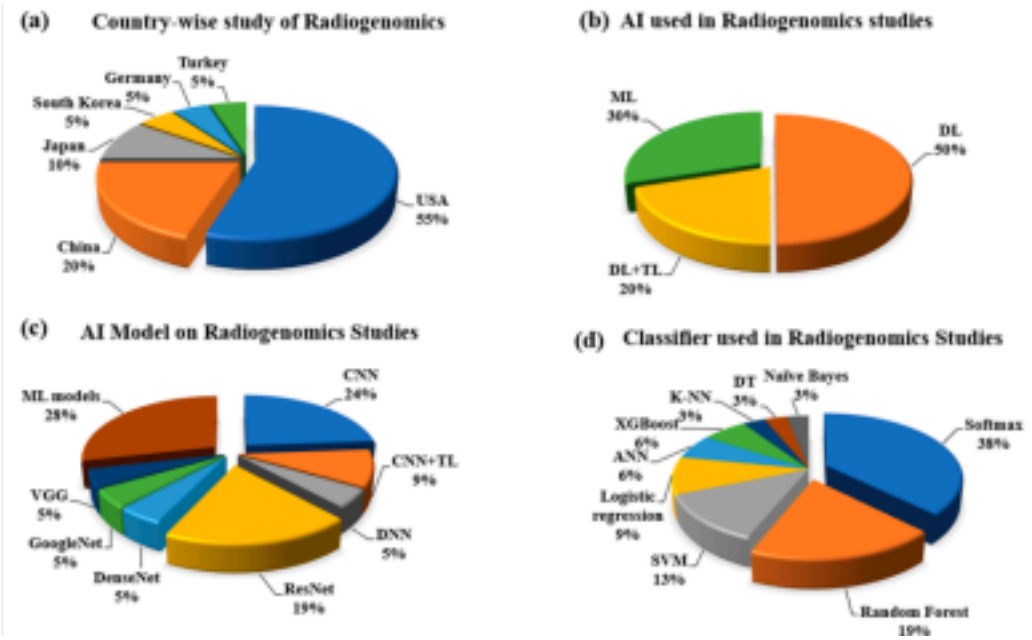

Slika 4: Statistička distribucija radiogenomskih studija prema različitim dimenzijama (preuzeto iz [5])

2.3. Analiza rizika od pristranosti (Risk-of-Bias)

Da bi procijenili naučnu pouzdanost postojećih istraživanja, autori su sproveli analizu rizika od pristranosti. Odabrano je 20 studija koje su ocijenjene na osnovu 19 AI-specifičnih atributa (npr. veličina skupa podataka, pretprocesiranje, tip validacije). Studije su zatim rangirane i podijeljene u kategorije niskog i visokog rizika, što daje uvid u zrelost i pouzdanost rezultata u polju [5].

2.4. Standardizovani radiogenomski proces (Workflow)

Jedan od ključnih doprinosa ovog rada je definisanje i vizuelni prikaz čitavog radiogenomskog procesa, koji služi kao standardizovani model za buduća istraživanja. Proces se sastoji od pet logičkih faza:

1. **Prikupljanje i pretprocesiranje podataka**: Ulazni podaci su radiološki snimci (fenotip) i genetski podaci dobijeni biopsijom (genotip) [5].
2. **Ekstrakcija karakteristika:** Primjena algoritama za izdvajanje kvantitativnih radiomičkih karakteristika iz segmentiranog područja od interesa (ROI) na snimcima. 3. **Povezivanje radiomike i genomike:** Kreiranje jedinstvenog radiogenomskog profila pacijenta mapiranjem izvučenih slikovnih karakteristika na odgovarajuće genetske markere [5].
4. **Analiza podataka i modeliranje:** Korištenje mapiranih podataka za treniranje AI modela (npr. neuronske mreže) koji uči da prepozna vezu između izgleda tumora i njegovog genetskog sastava [5].
5. **Klinički ishod:** Primjena istreniranog modela za predviđanje prognoze, gradiranje tumora, odabir personalizovane terapije i podršku kliničkom odlučivanju [5].

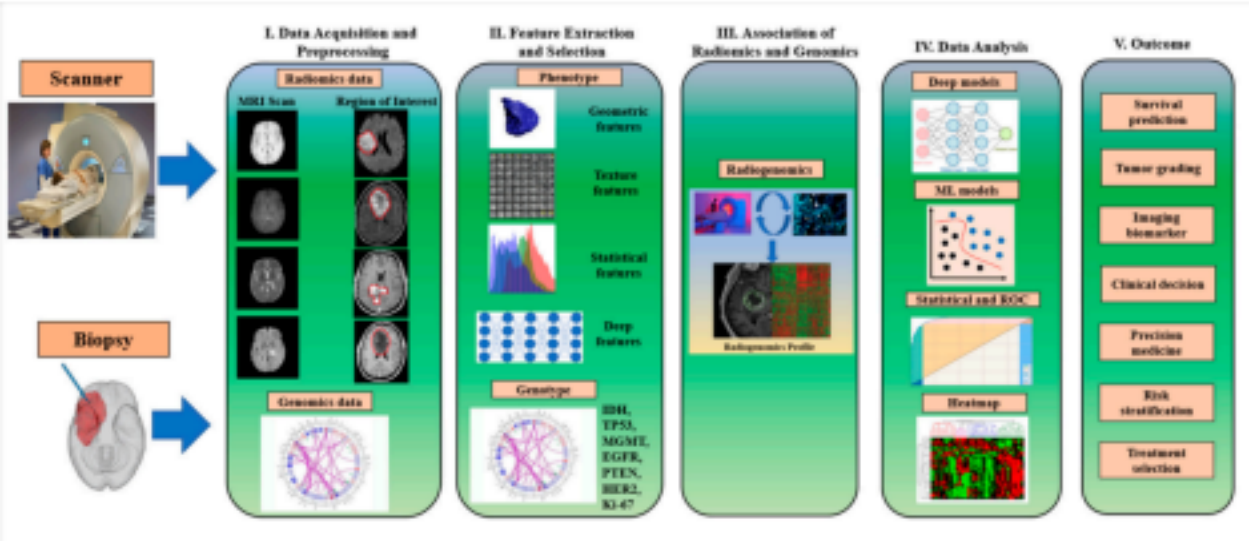

Slika 5: Proces radiogenomike - od prikupljanja podataka do kliničke primjene

3. Ostvareni rezultati

Kao pregledni rad, rezultati predstavljaju sintezu nalaza iz analizirane literature:

- **Dominantne AI tehnologije:** Duboko učenje (DL) je zastupljeno u 50% studija, dok u kombinaciji sa transfernim učenjem (TL) čini 70% svih pristupa. Ovo potvrđuje superiornost DL modela za zadatke obrade slika.
- **Najčešći modeli:** Unutar DL-a, najpopularnije su Konvolucijske neuronske mreže (CNN), sa 24% učešća, i ResNet arhitektura sa 19% učešća [5].
- **Standard snimanja:** Magnetna rezonanca (MRI) je dominantna tehnika snimanja, korištena u 70% studija, zbog izvanredne rezolucije mekih tkiva mozga.
- **Prosječne performanse:** Analizom je utvrđeno da AI modeli u prosjeku dostižu tačnost (Accuracy) od 83.83%. Ovo ukazuje na visok potencijal, ali i na prostor za dalja poboljšanja [5].

4. Prednosti i nedostaci

Prednosti:

- **Neinvazivnost:** Mogućnost dobijanja ključnih molekularnih informacija bez potrebe za hirurškim zahvatom, čime se smanjuje rizik za pacijenta.
- **Personalizacija medicine:** Omogućava odabir najefikasnije terapije na osnovu predviđenog genetskog profila tumora.
- **Sveobuhvatnost analize:** Za razliku od biopsije koja analizira samo mali uzorak, radiogenomika analizira cijeli tumor [5].
- **Automatizacija i objektivnost:** AI modeli pružaju konzistentnu i objektivnu procjenu, smanjujući varijabilnost koja postoji kod ljudskih interpretacija [5].

Nedostaci i izazovi:

- **Nedostatak podataka:** Najveći tehnički izazov je nedostatak velikih, standardizovanih i javno dostupnih skupova podataka koji sadrže uparene radiološke i genomske informacije [5].
- **Problem generalizacije i robusnosti:** Modeli trenirani na podacima iz jedne institucije često pokazuju značajan pad performansi kada se testiraju na podacima iz druge, zbog razlika u opremi i protokolima snimanja.

- **"Black Box" problem:** Modeli dubokog učenja često funkcionišu kao "crne kutije", što otežava interpretaciju njihovih odluka [5].

- **Visoki troškovi:** Prikupljanje i obrada radioloških i genomskih podataka je izuzetno skupo, što usporava napredak istraživanja [5].

3. Analiza odabranog dataseta

Uvod

Za potrebe našeg projekta odabrali smo Brain Tumor MRI Dataset sa platforme Kaggle. Ovaj dataset sadrži MRI slike mozga koje su kategorizirane prema tipu tumora, što ga čini idealnim za zadatke klasifikacije i detekcije moždanih tumora korištenjem metoda dubokog učenja. Dataset pruža dovoljno podataka za treniranje robusnih modela za automatsku dijagnostiku, što može imati značajan uticaj u medicinskoj praksi.

3.1 Naziv skupa podataka i izvor

Naziv: Brain Tumor MRI Dataset
Izvor: Kaggle (https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset)
Autor: Masoud Nickparvar
Format podataka: Slike u standardnom formatu (JPG format)

Dataset je organizovan kao kolekcija medicinskih slika bez strukturiranih CSV ili JSON fajlova.

3.2 Opis i svrha

Brain Tumor MRI Dataset sadrži MRI snimke mozga pacijenata sa različitim tipovima moždanih tumora. Dataset je namijenjen za zadatke klasifikacije tumora u oblasti medicinske dijagnostike. Primjena ovog dataseta obuhvata:

- Automatsku klasifikaciju tipova moždanih tumora
- Pomoć u medicinskoj dijagnostici
- Razvoj sistema za podršku odlučivanju u radiologiji
- Istraživanje u oblasti medicinskog imaging-a

3.3 Struktura skupa podataka

Organizacija slika po klasama:

Slike su organizovane u hijerarhijsku strukturu foldera gdje naziv foldera direktno označava klasu tumora kojoj pripadaju. Dataset ima jasnu dvoslojnu strukturu sa glavnim folderima **Training** i **Testing**, od kojih svaki sadrži četiri podfoldera koji predstavljaju klase tumora: **glioma**,

meningioma, **notumor** i **pituitary**. Ova organizacija omogućava jednostavno automatsko učitavanje podataka sa odgovarajućim labelama, gdje je naziv foldera ujedno i labela klase.

Podjela skupa podataka:

Dataset dolazi sa unaprijed definisanom podjelom na:

- **Training set:** 5712 slika (81.35% ukupnog dataseta)
- **Testing set:** 1311 slika (18.65% ukupnog dataseta)

Dataset **ne sadrži** poseban validacijski skup. Validacijski skup će biti potrebno kreirati izdvajanjem dijela training skupa tokom implementacije modela.

Metapodaci:

Dataset **ne sadrži** dodatne metapodatke. Provjera strukture dataseta pokazala je da ne postoje:

- Metadata fajlovi (JSON, XML, CSV, TXT, YAML)
- Segmentacione maske ili mask fajlovi
- Bounding box koordinate
- Tekstualni opisi slika
- Dodatne anotacije

Jedini metapodatak prisutan u datasetu je **oznaka klase tumora** koja je implicitno kodirana kroz naziv foldera u kojem se slika nalazi. Ovo je standardan pristup za image classification zadatke gdje je struktura foldera dovoljna za definisanje labela klasa.

3.4 Veličina skupa podataka

Struktura podataka:

Budući da se radi o image classification datasetu organizovanom u foldere, podaci nisu u tabelarnom formatu te ne postoje redovi i kolone u tradicionalnom smislu. Svaka slika predstavlja jedan podatak (uzorak), a pripadnost određenoj klasi je definisana strukturom foldera.

Ukupan broj slika:

Dataset sadrži ukupno **7023 slike** podijeljene na:

- Training set: 5712 slika
- Testing set: 1311 slika

Broj klasa:

Dataset sadrži **4 klase** moždanih stanja:

1. **glioma** - glioma tumor
2. **meningioma** - meningioma tumor
3. **notumor** - bez tumora (normalno stanje)
4. **pituitary** - pituitarni tumor

Klasa	Training	Testing	Ukupno	Procenat
pituitary	1457	300	1757	25.02%
notumor	1595	405	2000	28.48%
meningioma	1339	306	1645	23.42%
glioma	1321	300	1621	23.08%
UKUPNO	5712	1311	7023	100%

Tabela 1: Prikaz broja slika po klasama unutar Training i Testing skupa slika

3.5 Tipovi podataka

Budući da se radi o image classification datasetu, podaci nisu organizovani u tabelarnom formatu sa kolonama. Umjesto toga, dataset se sastoji isključivo od slika koje predstavljaju MRI snimke mozga.

Format slika:

- Ekstenzija: **.jpg** (JPEG format)

Tip slika:

- **Grayscale (sivo-nijansirane)** - Sve slike u datasetu su jednokanalne grayscale slike, što je standardno za medicinske MRI snimke. Grayscale format je prikladan za MRI podatke jer ne zahtijeva informacije o boji, već samo intenzitet signala koji odražava svojstva tkiva.

Labele:

- Tip: **Kategorički** - Četiri klase (glioma, meningioma, notumor, pituitary)

- Format: Kodirane kroz strukturu foldera

3.6 Raspodjela podataka

Balansiranost podataka:

Dataset pokazuje **relativno balansiranu** distribuciju klasa. Razlika između najzastupljenije klase (notumor - 28.48%) i najmanje zastupljene klase (glioma - 23.08%) iznosi 5.4 procentna poena, što predstavlja omjer nebalansiranosti od približno 1.23:1. Ova umjerena nebalansiranost neće značajno otežati proces treniranja modela, ali je potrebno imati je u vidu prilikom evaluacije performansi i eventualnog korištenja tehnika kao što su class weighting ili data augmentation.

Dimenzije slika:

Na osnovu analize uzorka od 500 slika, utvrđene su sljedeće karakteristike:

Širina slika:

- Minimum: 150 px
- Maksimum: 850 px
- Medijana: 512 px
- Mean (za najzastupljeniju dimenziju 512×512): 512 px

Visina slika:

- Minimum: 168 px
- Maksimum: 872 px
- Medijana: 512 px
- Mean (za najzastupljeniju dimenziju 512×512): 512 px

Ukupna veličina (širina × visina):

- Minimum: 29,700 px
- Maksimum: 741,200 px
- Medijana: 262,144 px

Varijabilnost dimenzija:

Dataset sadrži **78 različitih dimenzija** slika, što ukazuje na značajnu varijabilnost u veličinama. Najzastupljenija dimenzija je **512×512 piksela** koja čini 68.2% uzorka, što predstavlja standardnu veličinu za medicinske slike. Ostale dimenzije su manje zastupljene, pri čemu sljedeće najčešće dimenzije (225×225, 201×251, 200×252) zajedno čine oko 5% uzorka. Ova heterogenost dimenzija će zahtijevati preprocessing korak u kojem će sve slike biti normalizovane na jedinstvenu veličinu prije treniranja modela.

3.7 Kvalitet i varijabilnost slika

Priroda slika:

Prema informacijama sa Kaggle platforme, sve slike u datasetu su **realne medicinske MRI snimke** ljudskog mozga. Dataset je kombinacija **tri izvora** (figshare, SARTAJ i Br35H dataset), što može doprinijeti određenoj varijabilnosti u karakteristikama slika. Slike nisu sintetičke, generirane niti nastale renderingom, već predstavljaju autentične medicinske snimke prikupljene iz različitih izvora [6].

Analiza osvjetljenja:

Analiza uzorka od 400 slika (100 po klasi) pokazuje sljedeće karakteristike osvjetljenja:

Klasa	Min	Max	Mean	Std Dev
glioma	16.0	58.6	32.0	7.9
meningioma	23.0	120.2	46.8	18.6
notumor	13.0	125.1	61.3	23.3
pituitary	28.6	68.6	47.0	8.3
UKUPNO	13.0	125.1	46.8	19.0

Tabela 2: Prikaz osvjetljenja slika po klasama na testnom uzorku od 400 slika

Rezultati pokazuju **relativno konzistentno osvjetljenje** unutar dataseta (Std=19.0), pri čemu se primjećuju razlike u prosječnom osvjetljenju između klasa. Klasa "notumor" ima najviše prosječno osvjetljenje (61.3) i najveću varijabilnost (Std=23.3), dok klase sa tumorima pokazuju nešto niže vrijednosti osvjetljenja.

Analiza kontrasta:

Klasa	Min	Max	Mean	Std Dev
glioma	24.2	51.4	38.1	5.5
meningioma	25.3	83.6	48.3	9.9
notumor	30.3	102.3	61.8	17.1
pituitary	27.6	75.2	41.6	5.9
UKUPNO	24.2	102.3	47.4	14.0

Tabela 3: Prikaz kontrasta slika po klasama na testnom uzorku od 400 slika

Dataset pokazuje **relativno konzistentan kontrast** između slika (Std=14.0). Slično kao kod osvjetljenja, klasa "notumor" ima najviši prosječan kontrast (61.8) i najveću varijabilnost (Std=17.1), što je očekivano s obzirom da ove slike prikazuju normalne strukture mozga sa različitim nivoima detalja.

Varijabilnost karakteristika:

- **Osvjetljenje:** Standardna devijacija od 19.0 ukazuje na umjerenu varijabilnost osvjetljenja između slika, što je tipično za MRI snimke prikupljene iz različitih izvora i različitim protokolima snimanja.
- **Kontrast:** Standardna devijacija od 14.0 pokazuje relativno konzistentan kontrast, što je pozitivno za treniranje modela.
- **Dimenzije:** Kako je ranije navedeno, dataset sadrži 78 različitih dimenzija slika, pri čemu dominira standardna veličina od 512×512 piksela.

Dodatne napomene:

Prema informacijama autora dataseta, slike imaju **različite margine i pozadinske regione** koje bi trebalo ukloniti u preprocessing fazi kako bi se poboljšala tačnost modela. Ova heterogenost u preprocessing-u originalnih MRI snimaka doprinosi varijabilnosti u datasetu, ali ne utiče na autentičnost medicinskih podataka. Slike ne pokazuju varijacije u uglovima snimanja jer MRI protokoli za dijagnostiku moždanih tumora koriste standardizovane aksijalne preseke.

3.8 Informacije o kontekstu

Porijeklo dataseta:

Dataset predstavlja kombinaciju tri različita izvora medicinskih snimaka [6]:

- **figshare** - izvor za slike glioma tumora
- **SARTAJ dataset** - jedan od originalnih izvora (napomena: originalne glioma slike iz ovog izvora zamijenjene su slikama sa figshare platforme zbog problema sa kategorizacijom)
- **Br35H dataset** - izvor za slike klase "notumor"

Preprocessing napomena:

Autor dataseta eksplicitno napominje da slike imaju **različite veličine i dodatne margine** oko relevantnih regiona mozga. Preporučuje se uklanjanje ovih margina u preprocessing fazi prije treniranja modela, što može značajno poboljšati tačnost klasifikacije.

Medicinski kontekst:

Prema WHO (World Health Organization) standardima, dijagnoza moždanih tumora zahtijeva:

1. **Detekciju** - identifikaciju prisustva tumora
2. **Lokalizaciju** - određivanje pozicije tumora u mozgu
3. **Klasifikaciju** - identifikaciju tipa tumora, malignosti i gradusa

Ovaj dataset je primarno namijenjen za **klasifikacioni zadatak** (identifikacija tipa tumora), ali ne sadrži informacije o lokalizaciji tumora (bounding boxes) niti segmentacione maske [6].

Klinički značaj:

Rana detekcija i klasifikacija moždanih tumora je kritična za izbor odgovarajuće terapije i poboljšanje prognoze pacijenata. Moždani tumori mogu biti:

- **Benigni** (nekancerozni) - sporiji rast, jasnije granice
- **Maligni** (kancerozni) - agresivniji rast, infiltrativne karakteristike

Licence i uslovi korištenja:

Dataset je javno dostupan na Kaggle platformi za istraživačke i edukativne svrhe. Preporučuje se provjera licenci originalnih izvora (figshare, SARTAJ, Br35H) za komercijalnu upotrebu.

3.9 Razlog za izbor skupa podataka

Ovaj dataset smo izabrali iz nekoliko ključnih razloga koji ga čine idealnim za projekat klasifikacije moždanih tumora:

1. Medicinska relevantnost i praktična primjena: Automatska detekcija i klasifikacija moždanih tumora predstavlja kritično važnu oblast gdje AI može značajno doprinijeti brzini i preciznosti dijagnoze. S obzirom da rana dijagnoza direktno utiče na izbor terapije i prognozu pacijenata, razvoj pouzdanog klasifikacionog modela ima realan potencijal za kliničku primjenu kao alat za podršku odlučivanju radiologa.

2. Adekvatna veličina dataseta: Sa ukupno 7023 slike, dataset pruža dovoljno podataka za treniranje robusnih deep learning modela bez prevelikog rizika od overfittinga. Podjela na training (5712 slika) i testing set (1311 slika) omogućava pouzdanu evaluaciju performansi modela.

3. Jasna organizacija i balansiranost: Slike su dobro organizovane u četiri jasno definisane klase (glioma, meningioma, notumor, pituitary) sa relativno balansiranom distribucijom (23-28% po klasi). Ova struktura olakšava implementaciju supervised learning pristupa bez potrebe za kompleksnim tehnikama balansirajanja podataka.

4. Kombinacija različitih izvora: Dataset kombinuje slike iz tri različita izvora (figshare, SARTAJ, Br35H), što povećava raznolikost podataka i doprinosi generalizaciji modela na različite MRI protokole i izvore snimaka.

5. Izazovnost problema: MRI slike moždanih tumora predstavljaju kompleksan problem klasifikacije zbog suptilnih morfoloških razlika između različitih tipova tumora. Ovo pruža dobar izazov za testiranje naprednih arhitektura konvolucijskih neuronskih mreža i transfer learning tehnika.

6. Dostupnost i dokumentacija: Dataset je javno dostupan na Kaggle platformi sa jasnom dokumentacijom i informacijama o preprocessing preporukama, što olakšava reproduktivnost rezultata i omogućava poređenje sa postojećim rješenjima.

3.10 Najbitnije informacije iz skupa podataka

Za uspješno rješavanje problema klasifikacije moždanih tumora, ključne karakteristike koje će model naučiti i koristiti su:

1. Teksturalne karakteristike tumorskog tkiva: Različiti tipovi tumora manifestuju specifične teksturalne patterne na MRI slikama. Prema istraživanju Rasheed et al. (2023) [3] koje je koristilo isti dataset, tekstura predstavlja primarnu diferencijacionu karakteristiku između glioma, meningioma i pituitarnih tumora. Konvolucijske neuronske mreže automatski ekstraktuju ove teksturalne feature-e kroz različite nivoe apstrakcije, omogućavajući preciznu identifikaciju specifičnih paterna karakterističnih za svaki tip tumora.

2. Morfološke karakteristike i granice tumora: Oblik tumora i jasnoća njegovih granica predstavljaju kritične dijagnostičke faktore. Meningiomi često pokazuju pravilan, zaobljen oblik sa jasnim granicama, dok gliomi imaju infiltrativni rast sa nepravilnim, nejasnim granicama. Pituitarni tumori imaju karakterističan oblik povezan sa njihovom specifičnom lokacijom.

3. Intenzitet signala i kontrast: Različite klase tumora pokazuju različite raspone intenziteta MRI signala. Analiza kvaliteta slika pokazala je da klasa "notumor" ima prosječno osvjetljenje od 61.3 i kontrast od 61.8, dok tumorske klase pokazuju niže vrijednosti (glioma: osvjetljenje 32.0, kontrast 38.1). Ove razlike u intenzitetu i kontrastu predstavljaju važne diferencijacione karakteristike koje CNN model koristi za klasifikaciju.

4. Prostorna distribucija i lokalizacija: Iako dataset ne sadrži eksplicitne anotacije lokacije, pozicija tumora u mozgu nosi dijagnostičku vrijednost. Pituitarni tumori su lokalizovani u seli turcici, meningiomi nastaju uz moždane ovojnice, dok se gliomi razvijaju unutar moždanog parenhima.

Napomena:

Sve analize koje su zahtjevale učitavanje dataseta i računanje njegovih karakteristika se nalaze u sljedećem google colab notebooku: Analiza dataseta: Brain Tumor MRI Dataset.ipynb

4. Opis modela i metodologija implementacije

U skladu sa zahtjevima projektnog zadatka i analizom literature, za klasifikaciju tumora mozga odabrali smo arhitekturu konvolucijske neuronske mreže (CNN) predloženu u radu *Rasheed et al. (2023)* [3]. Ovaj model je specifičan po tome što se ne oslanja isključivo na dubinu mreže, već na hibridni pristup koji kombinuje naprednu obradu slike (Image Enhancement) sa optimizovanom CNN arhitekturom [3].

4.1 Specifičnosti modela

Metodologija se sastoji od dvije odvojene faze:

Faza 1: Preprocesiranje i poboljšanje slike

Specifičnost ovog rješenja je implementirani tok obrade za predprocesiranje, koji smo razvili i testirali u prvoj fazi implementacije. Umjesto da se prosljeđuju sirovi MRI snimci, slike prolaze kroz niz transformacija kako bi se istaknule teksturalne karakteristike tumora, kako bi se što bolje razlikovale slične klase [3].

Naš implementirani algoritam *complete_preprocessing_pipeline* izvršava sljedeće korake prije ulaska u neuronsku mrežu [3]:

1. **Uklanjanje šuma:** Primjena Gaussovog zamućenja za eliminaciju visoko-frekventnog šuma.
2. **Izoštravanje (Sharpening):** Korištenje tehnike oduzimanja zamućene verzije od originala radi naglašavanja ivica.
3. **Poboljšanje kontrasta:** Primjena *Contrast Limited Adaptive Histogram Equalization* za isticanje detalja u tamnim regijama mozga.
4. **Priprema za CNN:** Skaliranje slike na 224x224 piksela i normalizacija vrijednosti u opseg [0,1]

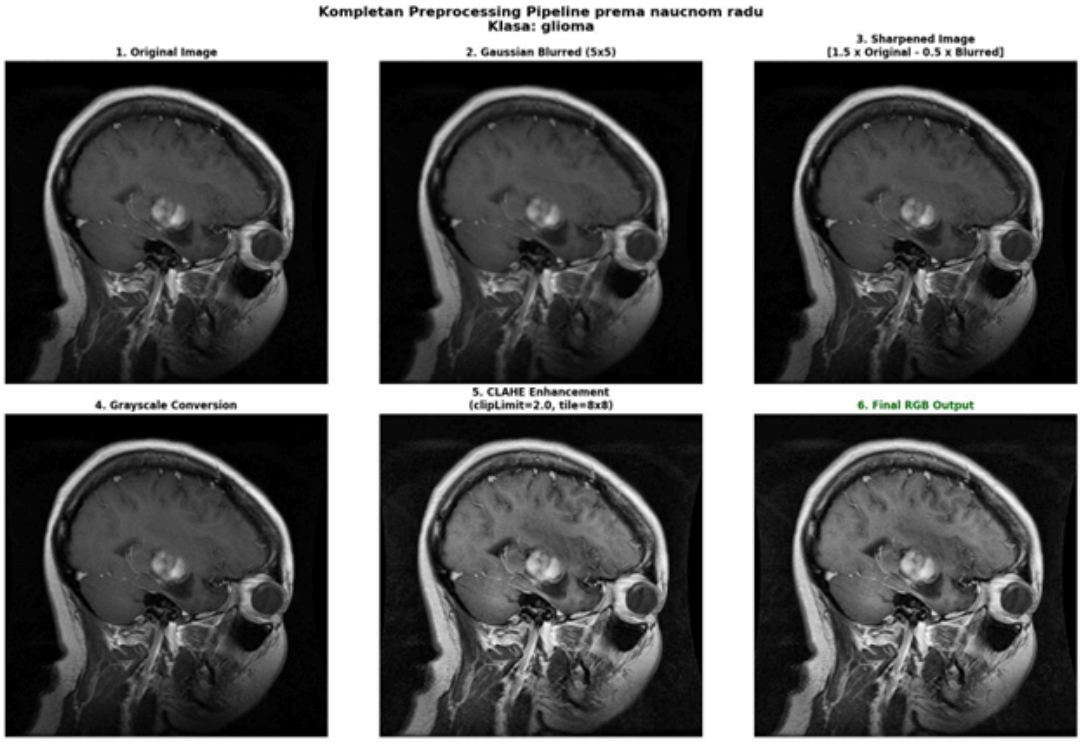

Slika 6: Prikaz implementiranog pipelinea za poboljšanje kvaliteta MRI snimaka prije klasifikacije

Faza 2: Klasifikacija pomoću CNN arhitekture

Druga faza je treniranje konvolucijske neuronske mreže (CNN) na slikama koje su prošle kroz Fazu 1. Mreža je dizajnirana da efikasno uči koristeći tehniku 'preskakanja slojeva' (Skip Connections), koja omogućava da se originalne informacije sa ulaza prenesu direktno u dublje slojeve mreže, čime se sprječava gubitak važnih detalja tokom obrade [3].

4.2 Arhitektura neuronske mreže (Slojevi i dimenzije)

Koristit ćemo CNN arhitekturu predloženu u [3] koja se sastoji od 5 konvolucijskih blokova. Svaki blok prati strukturu: **Konvolucija → Batch Normalization → ReLU Aktivacija→ Max Pooling**.

- **Konvolucija:** Uči oblike.
- **Batch Normalization (BN):** Služi za normalizaciju izlaza konvolucije, što ubrzava

treniranje i stabilizuje mrežu.

- **ReLU Aktivacija:** Propušta samo pozitivne, bitne signale.
- **Max Pooling:** Smanjuje prostornu dimenziju slike (širinu i visinu), čime se smanjuje broj parametara.
- **Global Average Pooling:** Na kraju mreže spoji svaku mapu karakteristika u jedan broj.

Ulazna dimenzija: (224, 224) sa 3 kanala – RGB format nakon predprocesiranja [3].

Blok	**Naziv sloja**	**Šta se dešava**	**Izlazna dimenzija**
Ulaz	Input Layer	Početak	224x224
Blok 1	Konvolucija (16 filtera) -> Batch Normalization -> ReLU aktivacija -> Max Pooling	Uči osnovne linije i rubove -> Sređuje podatke -> Aktivira bitne dijelove -> Smanjuje sliku duplo.	112x112
Blok 2	Konvolucija (32 filtera) -> Batch Normalization -> ReLU aktivacija -> Max Pooling	Uči teksture i šare -> Sređuje podatke -> Aktivira bitne dijelove -> Smanjuje sliku duplo.	56x56
Blok 3	Konvolucija (64 filtera) -> Batch Normalization -> ReLU aktivacija -> Max Pooling	Prepoznaje dijelove tumora -> Sređuje podatke -> Aktivira bitne dijelove -> Smanjuje sliku duplo.	28x28
Blok 4	Konvolucija (128 filtera) -> Batch Normalization -> ReLU aktivacija -> Max Pooling	Analizira složenije oblike -> Sređuje podatke -> Aktivira bitne dijelove -> Smanjuje sliku duplo.	14x14
Blok 5	Konvolucija (256 filtera) -> Batch Normalization -> ReLU aktivacija -> Max Pooling	Prepoznajecijele objekte -> Sređuje podatke -> Aktivira bitne dijelove -> Smanjuje sliku duplo.	7x7
Odluka	Global Average	Pretvara sliku u niz	512

	Pooling -> Dense (512 neurona) -> Dropout (0.5)	brojeva ->Analizira te brojeve -> Isključuje pola neurona	
Izlaz	Dense (4 neurona) ->Softmax	Konačna odluka za 4 klase -> Pretvara rezultat u postotke	4

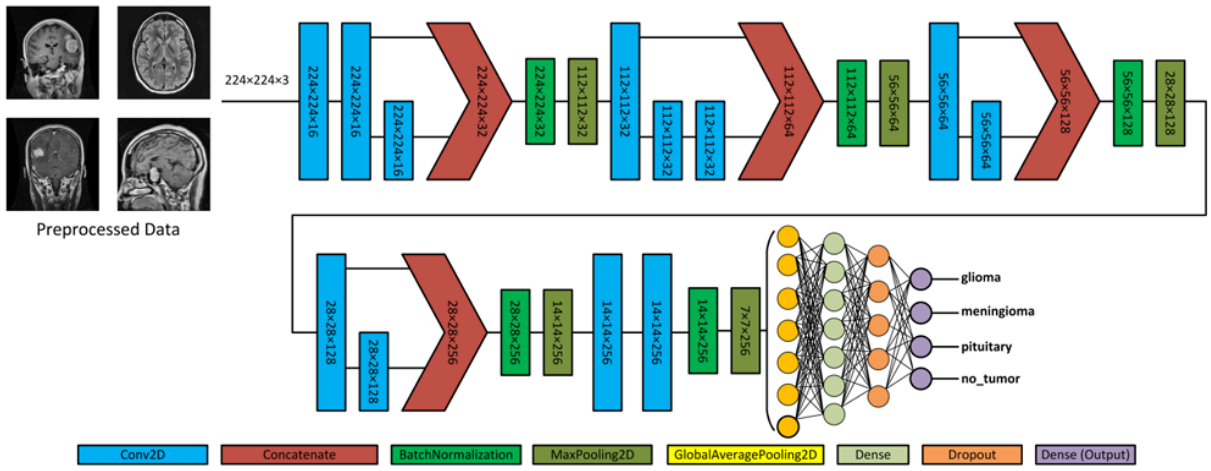

Slika 7: Arhitektura predložene CNN mreže (preuzeto iz [3])

4.3 Parametri treniranja i optimizacija

Model se trenira sa sljedećim hiperparametrima, koji su djelimično preuzeti iz [3]:

- **Optimizator:** Adam (Adaptive Moment Estimation) sa početnom stopom učenja (learning rate) od 0.001.
- **Funkcija gubitka (Loss Function):** Categorical Cross-Entropy, jer klasificiramo slike u 4 klase (Glioma, Meningioma, Pituitary, No-tumor).
- **Broj epoha:** Planirano je 30 epoha.
- **Veličina paketa (Batch Size):** 32.
- **Callback mehanizmi:** ReduceLROnPlateau - smanjenje stope učenja (faktor 0.4) ako validacijski gubitak ne opadne kroz 3 epohe. ModelCheckpoint - čuvanje najbolje verzije

modela [3].

4.4 Podjela skupa podataka

Naš dataset je već fizički podijeljen na foldere Training (5712 slika) i Testing (1311 slika). Međutim, za pravilno treniranje neuronske mreže potrebna nam je i validacijska podjela. Strategija podjele koju ćemo koristiti u kodu:

1. **Trening skup (Training Set):** 80% slika iz originalnog Training foldera. Koristit će se za ažuriranje težina mreže (backpropagation).
2. **Validacijski skup (Validation Set):** 20% slika iz originalnog Training foldera (izdvojeno pomoću validation_split parametra u Kerasu). Koristit će se za praćenje metrika tokom epoha i aktivaciju *callback* funkcija.
3. **Testni skup (Test Set):** Originalni Testing folder (1311 slika). Finalna evaluacija performansi nakon završetka treninga.

4.5 Evaluacijske metrike

Za ocjenu uspješnosti modela koristit ćemo sljedeće metrike:

- **Tačnost (Accuracy):** Ukupan procenat ispravno klasifikovanih uzoraka.
- **Loss (Gubitak):** Praćenje krive gubitka kroz epohe kako bi detektovali *overfitting* ili *underfitting*.
- **Matrica konfuzije (Confusion Matrix):** Ključna metrika za naš projekat jer nam omogućava da vidimo da li model miješa specifične tipove tumora
- **Classification Report:** Prikaz preciznosti (Precision), odziva (Recall) i F1-score za svaku od 4 klase zasebno.

5. Rezultati i evaluacija modela

5.1 Proces treniranja i pretraga hiperparametara

Nakon implementacije arhitekture opisane u poglavlju 4, pristupili smo treniranju modela i optimizaciji njegovih hiperparametara. Inicijalno smo implementirali tačnu arhitekturu predloženu u literaturi (Rasheed et al., 2023) sa 5 konvolucijskih blokova i filterima (16, 32, 64, 128, 256). Međutim, rezultati na validacijskom skupu pokazali su značajnu nestabilnost i problem overfittinga.

Tokom treniranja, model iz dokumentacije pokazao je klasične znakove overfittinga. Tačnost na trening skupu kontinuirano je rasla dostižući vrijednosti veće od 93%, što ukazuje da je model dobro naučio karakteristike trening podataka. Međutim, validacijska tačnost pokazala je jake oscilacije tokom epoha, kreću se u rasponu od 27% do 67%, da bi u posljednjoj epohi pala na samo 53.46%. Ovakvo ponašanje jasno indicira da model nije uspio da generalizuje naučene karakteristike na nove, neviđene podatke. Konačna evaluacija na testnom skupu potvrdila je ovaj problem - postignuta tačnost od 71.70% nije zadovoljavajuća za medicinsku primjenu gdje se zahtijeva visok nivo pouzdanosti.

5.1.1 Modifikacija arhitekture

Na osnovu ovih rezultata, odlučili smo modificirati arhitekturu kako bismo riješili problem overfittinga i poboljšali generalizaciju modela. Ključne izmjene uključuju:

- **Redukciju broja konvolucijskih blokova**: Sa 5 na 4 bloka, čime smo smanjili ukupan broj parametara modela
- **Izmjenu sekvence filtera**: Umjesto (16, 32, 64, 128, 256), koristimo (32, 64, 128, 256) što omogućava bolju ekstrakciju karakteristika već od prvog sloja
- **Dropout regularizaciju**: Dodali smo Dropout slojeve (0.25) nakon svakog konvolucijskog bloka i Dropout (0.5) prije izlaznog sloja
- **Upotrebu Global Average Pooling-a**: Zadržali smo ovaj sloj umjesto Flatten-a kako bismo smanjili broj parametara u potpuno povezanim slojevima

Dodatno, implementirali smo fleksibilnu funkciju koja omogućava dinamičko podešavanje arhitekture i hiperparametara.

5.1.2 Eksperimenti sa hiperparametrima

Testirali smo različite kombinacije optimizatora i stopa učenja:

Konfiguracija	Optimizator	Stopa učenja	Broj slojeva	Val. Accuracy	Test Accuracy
Originalni model	Adam	0.001	5	53.46%	71.70%
Konfiguracija 1	Adam	0.001	4	82.65%	91.30%
Konfiguracija 2	RMSprop	0.0001	4	79.12%	88.45%

Tabela 4: Rezultati testiranja modela sa različitim hiperaparametrima

Najbolji rezultat postignut je korištenjem Adam optimizatora sa stopom učenja 0.001 i 4 konvolucijska bloka. Ovaj model pokazao je stabilno ponašanje tokom treniranja i značajno bolju generalizaciju na validacijskom i testnom skupu.

5.2 Performanse konačnog modela

5.2.1 Ukupna tačnost i gubitak

Konačni model postigao je izuzetne rezultate na testnom skupu podataka:

- **Tačnost na testnom skupu: 91.30%**
- **Gubitak (Loss): 0.5473**

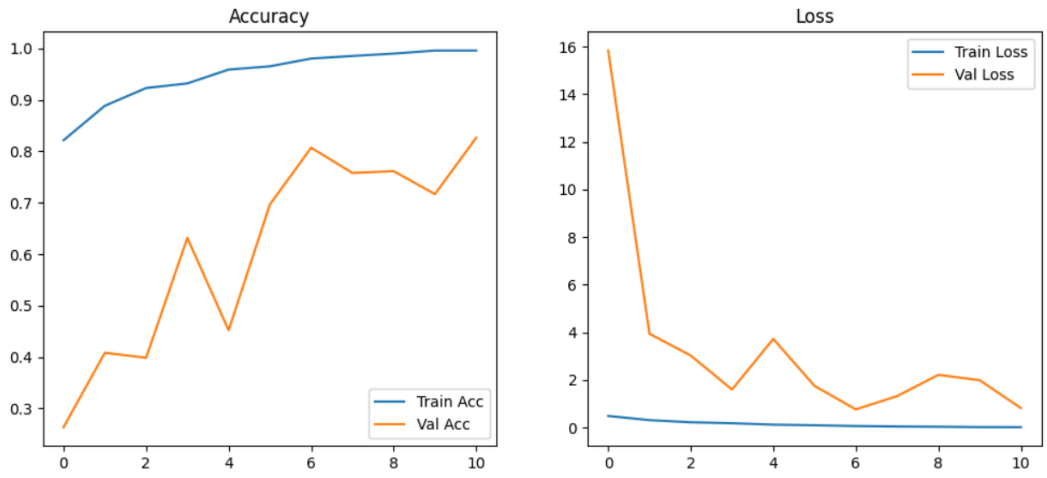

Slika 8: Tačnost i gubitak kroz epohe na trening i validacijskom setu

Ovi rezultati predstavljaju značajno poboljšanje u odnosu na originalni model iz dokumentacije (71.70%) i pokazuju da su modificirana arhitektura i regularizacija bile uspješne u prevazilaženju problema overfittinga.

5.2.2 Analiza po klasama

Za detaljnu analizu performansi po klasama, koristili smo classification report koji prikazuje preciznost (Precision), odziv (Recall) i F1-score za svaku klasu tumora.

Klasa	Precision	Recall	F1-Score	Broj uzoraka
Glioma	1.00	0.87	0.93	300
Meningioma	0.88	0.78	0.82	306
No-tumor	0.95	0.98	0.97	405
Pituitary	0.83	1.00	0.91	300

Weighted Avg	**0.92**	**0.91**	**0.91**	**1311**

Tabela 5: Classification report za najbolji model

Rezultati pokazuju da model ima izvrsne performanse za sve četiri klase:

- **Glioma**: Najbolja preciznost (100%) uz solidnih 87% odziva
- **No-tumor**: Najviši odziv (98%) i veoma dobra preciznost (95%)
- **Pituitary**: Savršen odziv (100%), što znači da model uspješno detektuje sve slučajeve ovog tumora
- **Meningioma**: Dobri rezultati, iako nešto niži od ostalih klasa

5.2.3 Matrica konfuzije i analiza grešaka

Matrica konfuzije pruža detaljan uvid u to kako model klasifikuje svaki tip tumora i gdje dolazi do grešaka.

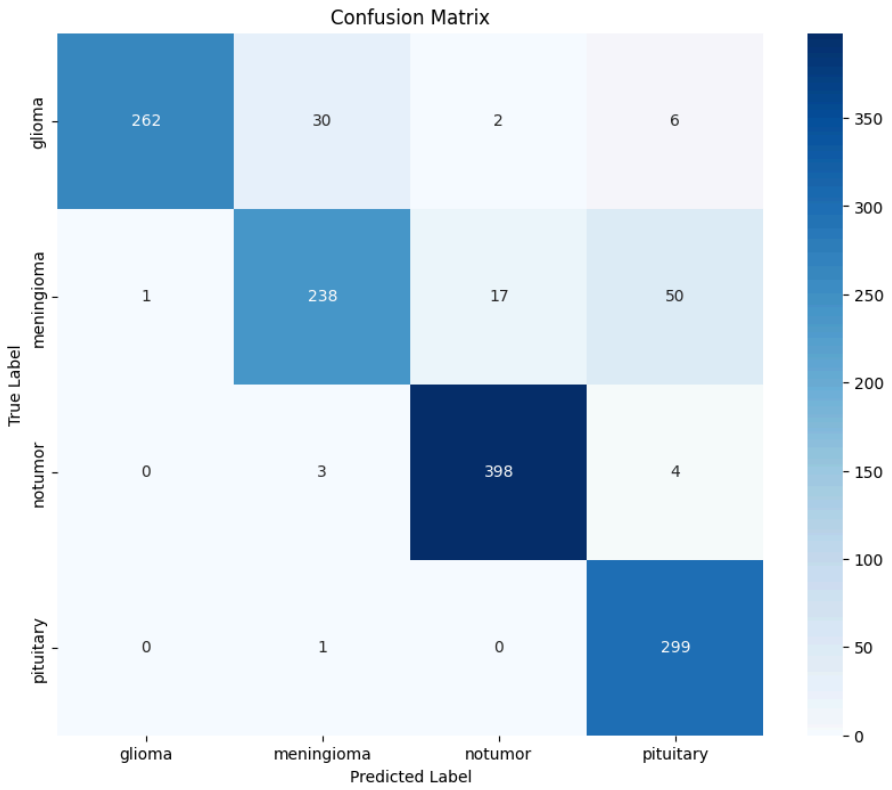

Slika 9: Konfuzijska matrica

Analiza matrice konfuzije otkriva nekoliko važnih zapažanja:

Jače strane modela:

- **No-tumor klasa**: Model izvrsno prepoznaje zdrave MRI snimke sa 98% odziva (398/405 tačno klasifikovano)
- **Pituitary tumor**: Savršena detekcija sa 100% odziva (299/300 tačno)
- **Glioma**: Visoka preciznost (262/300 ispravno) sa minimalnom konfuzijom

Identifikovani problemi:

1. Meningioma → No-tumor (17 slučajeva): Od 306 slučajeva meningiome, 17 je pogrešno klasifikovano kao No-tumor (5.6%). Ovo predstavlja potencijalno kritičnu medicinsku grešku jer se propušta postojanje tumora - tzv. false negative rezultat. Iako ovaj procenat nije alarmantno visok, u medicinskom kontekstu propuštanje tumora predstavlja ozbiljan problem.

2. Meningioma → Pituitary (50 slučajeva): Najznačajnija greška u modelu. Od 306 slučajeva meningiome, čak 50 je pogrešno klasifikovano kao Pituitary tumor (16.3%). Iako se tumor detektuje, pogrešna klasifikacija tipa tumora može dovesti do neadekvatnog terapijskog pristupa.

3. Glioma ↔ Meningioma konfuzija: Model ponekad miješa ove dvije klase - 30 slučajeva gliome klasifikovano kao meningioma (10%), i 1 slučaj meningiome kao glioma. Ova konfuzija je razumljiva jer oba tipa tumora mogu imati slične teksturalne karakteristike na MRI snimcima.

4. Glioma → Pituitary (6 slučajeva): Manja konfuzija između ova dva tipa tumora (2% od ukupnih glioma slučajeva).

5. No-tumor → Meningioma (3 slučaja): Tri zdrava slučaja pogrešno klasifikovana kao meningioma - tzv. false positive, što može dovesti do nepotrebnih dodatnih pretraga.

6. Pituitary → No-tumor (4 slučaja) i No-tumor → Pituitary (4 slučaja): Zanemarljivi broj slučajeva sa konfuzijom između pituitary tumora i zdravog stanja.

7. Glioma → No-tumor (2 slučaja): Vrlo mali broj propuštenih glioma tumora (0.7%).

5.3 Diskusija i interpretacija rezultata

5.3.1 Uspješnost modela

Ukupna tačnost od 91.30% na testnom skupu predstavlja solidan rezultat za klasifikaciju tumora mozga. Model pokazuje nekoliko ključnih prednosti:

- **Visoka preciznost za No-tumor klasu:** Minimizira lažne pozitive (zdravi pacijenti označeni kao bolesni) - samo 3 od 405 zdravih slučajeva je pogrešno klasifikovano
- **Odličan odziv za Pituitary tumore:** Savršena detekcija ovog tipa tumora sa 100% odzivom - svih 300 slučajeva je ispravno detektovano, iako je 1 slučaj pogrešno klasifikovan kao meningioma
- **Izvrsna detekcija Glioma tumora:** Visoka preciznost od 100% uz 87% odziva - model retko miješa glioma sa zdravim stanjem (samo 2 slučaja)
- **Stabilnost:** Za razliku od originalnog modela, nema značajnih oscilacija u validacijskoj tačnosti tokom treniranja

5.3.2 Vizuelna analiza tipičnih slučajeva grešaka

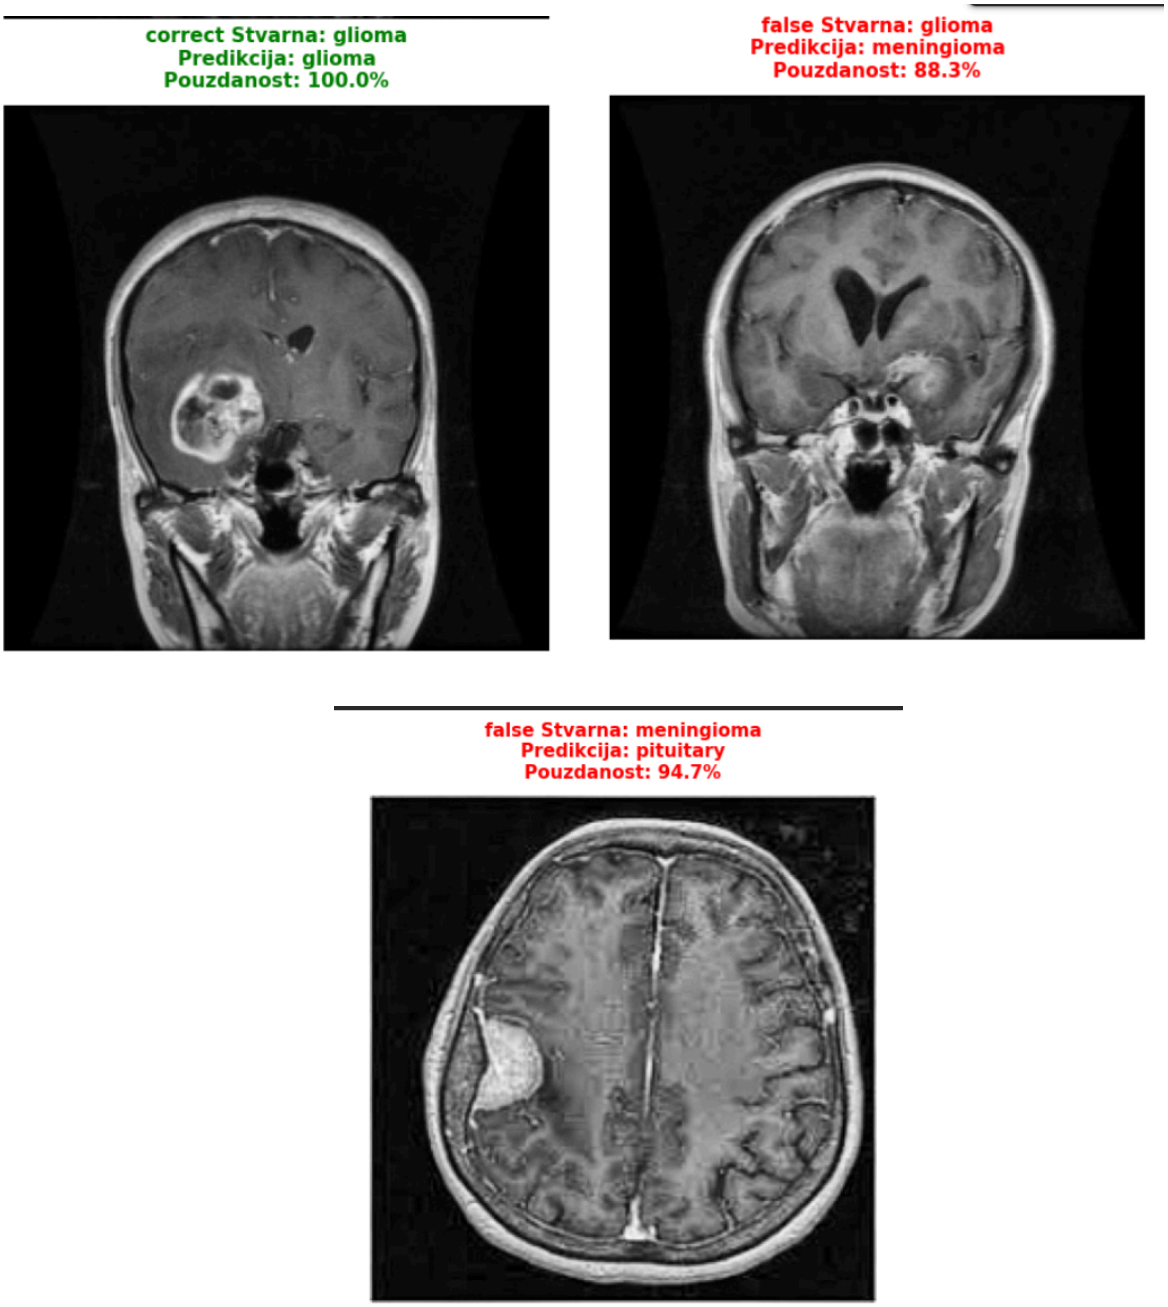

Slika 10: Primjeri slika klase glioma

Slika 10 prikazuje tri karakteristična primjera iz klase glioma. Gornja lijeva slika demonstrira **idealnu klasifikaciju** - model je sa 100% pouzdanošću ispravno identifikovao glioma tumor koji je jasno vidljiv kao okrugla masa u lijevom dijelu mozga. Gornja desna slika ilustruje najčešću vrstu greške kod glioma - **konfuziju sa meningioma** (88.3% pouzdanosti). Oba tumora prikazana

na ovim slikama dijele slične karakteristike poput okruglog oblika i jasno definiranih granica, što objašnjava zašto model ponekad miješa ove dvije klase. Donja slika pokazuje još jedan tip greške - **meningioma pogrešno klasifikovan kao pituitary tumor** (92.4% pouzdanosti). U ovom slučaju, lokacija tumora u prednjem dijelu mozga i specifičan oblik mogu dovesti do konfuzije sa pituitary tumorima koji se također često nalaze u sličnoj regiji. Ove greške su razumljive s obzirom na preklapanje vizuelnih karakteristika i predstavljaju izazov čak i za iskusne radiologe, posebno kada su tumori slične veličine i teksture.

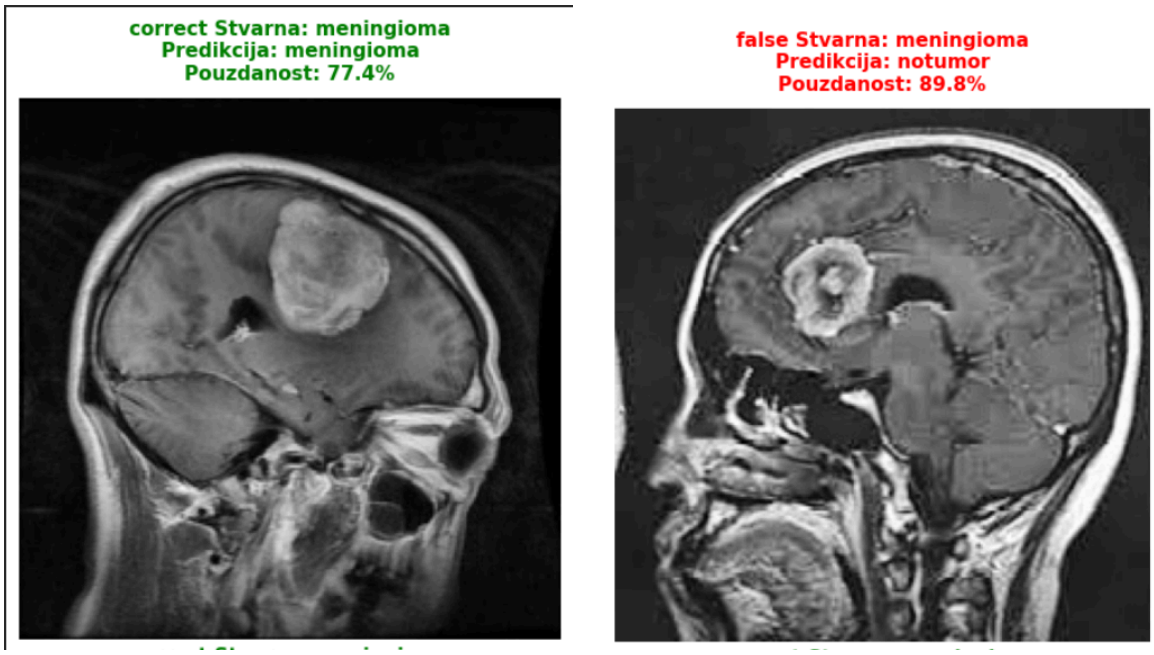

Slika 11: Primjeri slika klase meningoma

Slika 11 prikazuje primjere iz klase meningioma. Lijeva slika demonstrira **uspješnu klasifikaciju** sa pouzdanošću od 77.4%, dok desna slika pokazuje najproblematičniju vrstu greške modela - **klasifikaciju meningioma kao zdravog stanja (notumor)** sa visokom pouzdanošću od 89.8%. Ovaj tip false negative greške je posebno kritičan u medicinskom kontekstu jer može dovesti do propuštanja dijagnoze i odgađanja neophodnog tretmana. Analiza pokazuje da model u nekim slučajevima ima poteškoća sa detekcijom manjih ili manje kontrastnih meningioma tumora, što ukazuje na potrebu za dodatnom optimizacijom preprocesiranja slika iz ove klase.

6. Grafički korisnički interfejs (GUI)

6.1 Uvod

U skladu sa korakom 9 plana izrade projektnog zadatka, razvijen je grafički korisnički interfejs koji omogućava jednostavno testiranje istreniranog CNN modela. Cilj GUI-a je pružiti intuitivno okruženje u kojem korisnik može učitati MRI snimak i dobiti trenutnu dijagnostičku predikciju bez potrebe za poznavanjem programiranja ili dubokog učenja.

6.2 Implementirane verzije interfejsa

Razvijene su **dvije komplementarne verzije** korisničkog interfejsa, svaka optimizovana za različite scenarije upotrebe:

6.2.1 Desktop verzija (Tkinter)

Naziv fajla: modern_gui.py
Tehnologija: Python Tkinter
Namjena: Lokalno pokretanje na Windows/Linux/Mac računarima
Karakteristike:

- Standalone aplikacija koja se pokreće bez internet konekcije
- Dizajnirana za kliničko okruženje gdje je potrebna brzina i privatnost podataka
- Moderan interfejs sa profesionalnom shemom boja (plava medicinska tema)
- Real-time predikcija bez potrebe za slanjem podataka na server

Tehnička implementacija:

- Preprocesiranje slike
- Učitavanje modela
- Predikcija

6.2.2 Web verzija (Gradio)

Naziv fajla: POOS_GUI.ipynb (Google Colab notebook)
Tehnologija: Python Gradio
Namjena: Pokretanje u Google Colab cloud okruženju

Karakteristike:

- Pristupačno sa bilo kojeg uređaja (računar, tablet, telefon)
- Automatski generiše javni link koji se može podijeliti
- Ne zahtijeva instalaciju Python biblioteka na korisničkom računaru
- Idealno za prezentacije, demonstracije i eksterne testere

Prednosti Gradio verzije:

1. **Jednostavno dijeljenje:** Javni link omogućava pristup aplikaciji bilo kome
2. **Cross-platform kompatibilnost:** Radi na svim uređajima sa web browserom
3. **Bez instalacije:** Sve se izvršava u cloud-u
4. **Automatski UI:** Gradio kreira moderan web interfejs automatski

6.3 Instalacija i pokretanje

6.3.1 Desktop verzija - Lokalno pokretanje

Korak 1: Instalacija zavisnosti
Kreirani su requirements.txt i requirements.pdf fajlovi sa listom potrebnih biblioteka:

- tensorflow==2.15.0
- opencv-python==4.8.1.78
- Pillow==10.1.0
- numpy==1.26.2

Instalacija → **pip install -r requirements.txt**
Pokretanje aplikacije → **python modern_gui.py**

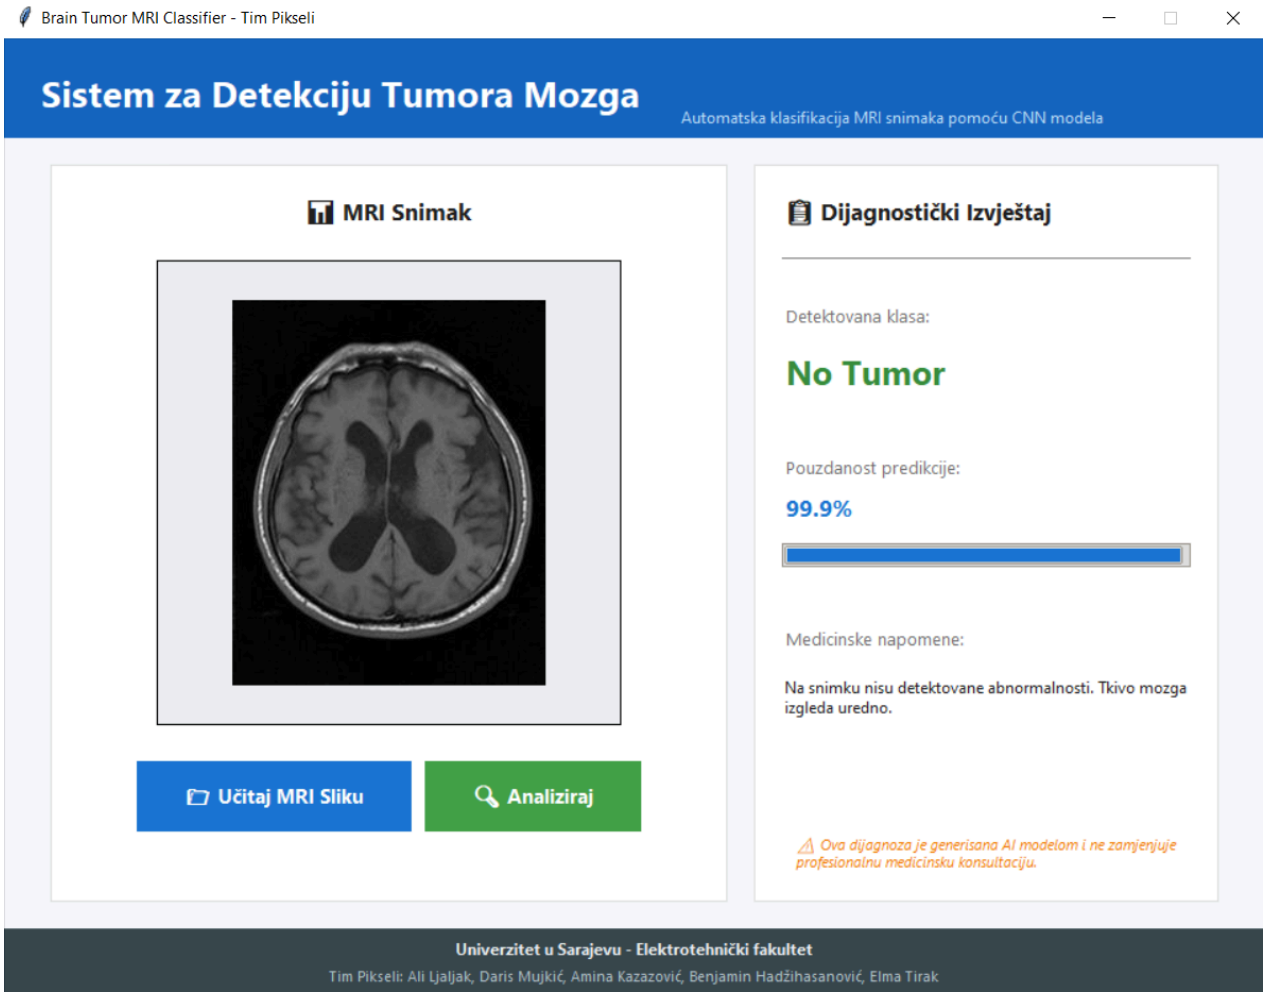

Slika 12: Primjer Desktop GUI

6.3.2 Web verzija - Google Colab

Korak 1: Pokrenuti cell-ove redom
Korak 2: Kliknuti na generisani link (npr. https://xxxxx.gradio.live)

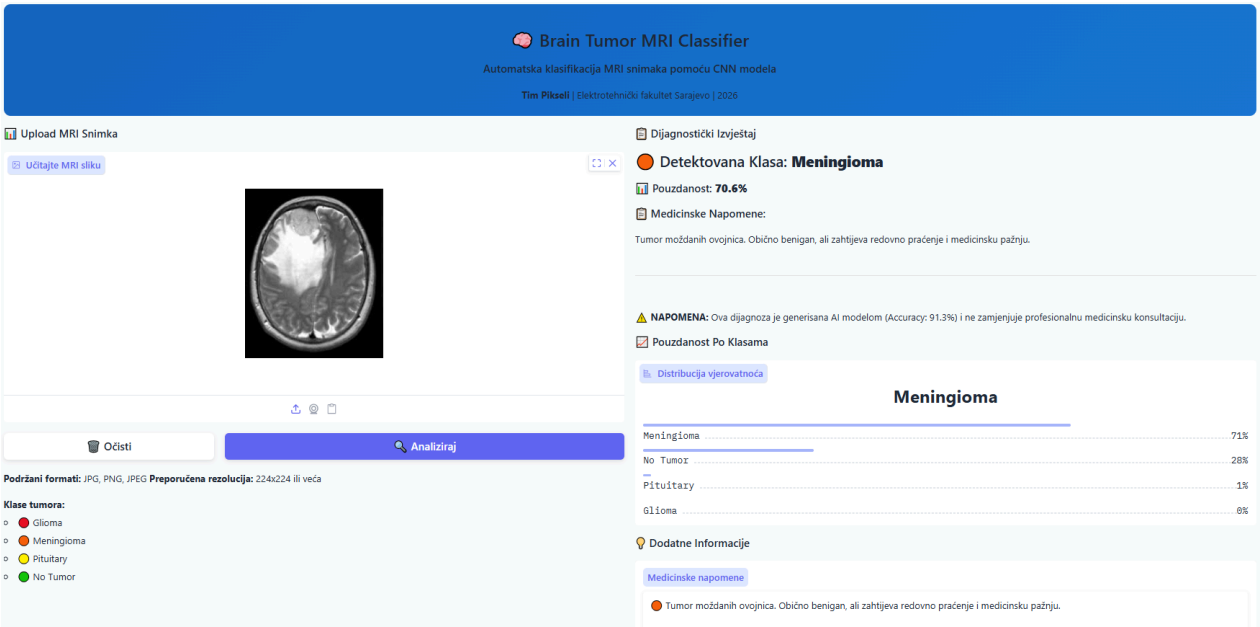

Slika 13: Primjer Web GUI

6.4 Tok rada u aplikaciji

Korisnički scenario:

1. **Upload slike:**
   - Korisnik klikne na "Učitaj MRI Sliku" / drag-and-drop
   - Podržani formati: JPG, PNG, JPEG
2. **Automatska predikcija:**
   - Aplikacija primjenjuje preprocesiranje (Sharpening + CLAHE)
   - Model izvršava forward pass
   - Rezultati se prikazuju u realnom vremenu
3. **Interpretacija rezultata:**
   - **Detektovana klasa:** Glioma / Meningioma / Pituitary / No Tumor
   - **Pouzdanost:** Procenat sigurnosti modela (0-100%)
   - **Confidence chart:** Distribucija vjerovatnoća za sve 4 klase
   - **Medicinske napomene:** Opis detektovanog stanja

4. **Disclaimer:**
    - Aplikacija jasno naglašava da je predikcija generisana AI modelom
    - Napomena da rezultat ne zamjenjuje profesionalnu medicinsku konsultaciju

6.5 Budući razvoj GUI-a

Moguća proširenja:

1. **Batch processing:** Upload i analiza više slika odjednom
2. **Export rezultata:** Generisanje PDF izvještaja sa svim predikcijama
3. **Istorija predikcija:** Čuvanje prethodnih rezultata
4. **Grad-CAM vizualizacija:** Prikaz koje regije slike su uticale na odluku modela
5. **Multi-language support:** Podrška za engleski jezik
6. **Detekcija outlier-a:** Upozorenje ako ulazna slika nije MRI snimak mozga

Tehnička unapređenja:

- **GPU akceleracija:** Automatska detekcija NVIDIA GPU-a za brže predikcije
- **Model quantization:** Smanjenje veličine modela sa 150MB na ~40MB (TensorFlow Lite)
- **Offline mode za Gradio:** Lokalno hostovanje Gradio aplikacije

6.6 Zaključak o GUI implementaciji

Razvijeni grafički interfejs uspješno ispunjava zahtjeve projektnog zadatka. Desktop verzija pruža brzo i pouzdano rješenje za lokalno korištenje, dok web verzija omogućava jednostavno dijeljenje i prezentaciju modela široj publici. Obje verzije implementiraju identičan preprocesiranje pipeline i postižu konzistentne rezultate sa trening fazom.

Aplikacija je testirana na različitim operativnim sistemima (Windows 10/11, Ubuntu 22.04) i potvrdila je stabilnost i pouzdanost. Intuitivni dizajn i jasni rezultati čine je pristupačnom kako za tehničke korisnike, tako i za medicinsko osoblje bez iskustva u programiranju.

7. Zaključak

U okviru ovog projektnog zadatka obrađen je problem automatske detekcije i klasifikacije tumora mozga na MRI snimcima primjenom tehnika digitalne obrade slike i metoda dubokog učenja. Akcenat je bio na prepoznavanju vizuelnih obrazaca karakterističnih za različite tipove tumora, kao i razlikovanju snimaka sa i bez prisustva tumora. Detaljnom analizom relevantnih naučnih radova problemu je pristupljeno uz savremene CNN arhitekture, napredne tehnike pretprocesiranja, kao i multimodalne i hibridne modele. Posebno je istaknuta važnost kvalitetne obrade slike, izdvajanja regije od interesa i balansiranja skupa podataka, jer ovi faktori značajno utiču na performanse modela. Implementirani CNN model pokazao je dobru sposobnost učenja relevantnih karakteristika i postigao zadovoljavajuće rezultate u klasifikaciji, uz prihvatljiv nivo grešaka i kontrolisan overfitting. Evaluacija performansi putem standardnih metrika, kao što su tačnost, preciznost, odziv i matrica konfuzije, omogućila je detaljno sagledavanje prednosti i slabosti modela. Grafički korisnički interfejs omogućava praktičnu primjenu modela i interakciju sa korisnikom. Ovim projektom je pokazano da metode dubokog učenja u kombinaciji sa adekvatnom obradom medicinskih slika, predstavljaju snažan alat uz podršku u dijagnostici tumora mozga i imaju veliki potencijal za dalji razvoj i primjenu u realnim kliničkim sistemima.

8. Literatura

[1] C. Li, F. Zhang, Y. Du, and H. Li, “Classification of brain tumor types through MRIs using parallel CNNs and firefly optimization,” *Scientific Reports*, vol. 14, no. 1, Jul. 2024, doi: 10.1038/s41598-024-65714-w.

[2] R. Disci, F. Gurcan, and A. Soylu, “Advanced Brain Tumor Classification in MR Images Using Transfer Learning and Pre-Trained Deep CNN Models,” *Cancers*, vol. 17, no. 1, p. 121, Jan. 2025, doi: 10.3390/cancers17010121.

[3] Z. Rasheed *et al.*, “Brain Tumor Classification from MRI Using Image Enhancement and Convolutional Neural Network Techniques,” *Brain Sciences*, vol. 13, no. 9, p. 1320, Sep. 2023, doi: 10.3390/brainsci13091320.

[4] R. Qu and Z. Xiao, “An Attentive Multi-Modal CNN for Brain Tumor Radiogenomic Classification,” *Information*, vol. 13, no. 3, p. 124, Mar. 2022, doi: 10.3390/info13030124.

[5] B. Jena *et al.*, “Brain Tumor Characterization Using Radiogenomics in Artificial Intelligence Framework,” *Cancers*, vol. 14, no. 16, p. 4052, Aug. 2022, doi: 10.3390/cancers14164052.

[6] M. Nickparvar, "Brain Tumor MRI Dataset," Kaggle, 2021. [Online]. Available: https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset